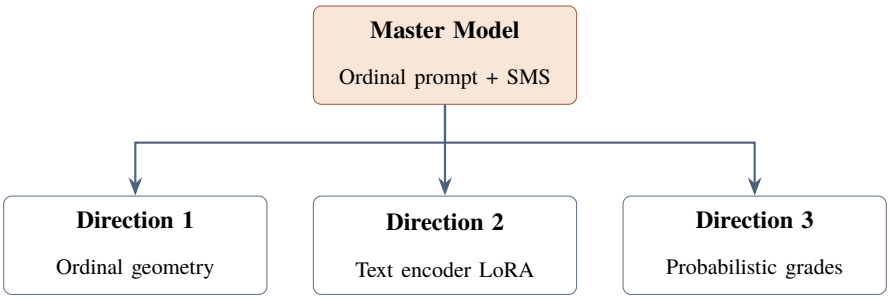
# Few-Shot Ordinal-Aware CLIP for Diabetic Retinopathy Grading

یک مدل پایه و سه جهت پژوهشی برای یادگیری نمایش ترتیبیِ درجه‌های بیماری
در فضای مشترک تصویر و متن




**مجموعه‌داده:** DeepDRiD (تصاویر فوندوس معمولی)

**مخزن کد:** `fewshot-ordinal-clip-dr`

**شاخه‌ها:** `master`، `direction1-ordinal-geometry`

`direction2-ordinal-text-lora`، `direction3-probabilistic-ordinal`

**معیار اصلی:** Quadratic Weighted Kappa (QWK) و افت خطا با فاصله از قطر

# فهرست مطالب

**مقدمه و نقشهٔ سند** ۱

**۱ مدل پایه (شاخهٔ master)** ۳

۱.۱ مسئله و ایدهٔ مدل . . . ۵

۱.۲ داده و few-shot protocol . . . ۵

۱.۲.۱ راهبرد تقسیم برای هر regime . . . ۷

۱.۳ preprocessing و data augmentation . . . ۸

۱.۴ معماری و blockهای مدل . . . ۱۰

۱.۴.۱ image branch: CLIP RN50 با LoRA . . . ۱۰

۱.۴.۲ text branch: prompt رتبه‌ای با OrdinalCLIP interpolation . . . ۱۱

۱.۴.۳ similarity matrix و پیش‌بینی . . . ۱۲

۱.۴.۴ Similarity Matrix Smoothing (SMS) . . . ۱۲

۱.۵ loss functionها . . . ۱۳

۱.۶ آموزش و بهینه‌سازی . . . ۱۴

۱.۷ ارزیابی و metricها . . . ۱۵

۱.۸ baselineها و ablationها . . . ۱۷

۱.۹ گردش کار آزمایش‌ها . . . ۱۸

**۲ جهت ۱: هندسهٔ ترتیبی مستقیم** ۲۰

۲.۱ انگیزه و شکاف پژوهشی . . . ۲۲

۲.۲ تفاوت با مدل پایه . . . ۲۲

۲.۳ معماری . . . ۲۳

۲.۴ grade vector initialisationها . . . ۲۳

۲.۵ ordinal geometric constraints . . . ۲۴

۲.۵.۱ distance ladder . . . ۲۴

۲.۵.۲ smooth path . . . ۲۵

۲.۵.۳ anchor . . . ۲۵

۲.۶ loss function کل . . . ۲۵

۷.۲ بهینه‌سازی . . . . . ۲۶
۸.۲ داده، ارزیابی و geometric diagnostics . . . . . ۲۶
۹.۲ baselineها و ablationها . . . . . ۲۷

**۳ جهت ۲: low-rank adaptation of the text encoder ۲۹**
۱.۳ انگیزه و شکاف پژوهشی . . . . . ۳۱
۲.۳ تفاوت با مدل پایه . . . . . ۳۱
۳.۳ معماری . . . . . ۳۲
۴.۳ توصیف‌های بالینی . . . . . ۳۲
۵.۳ low-rank adaptation of the text encoder . . . . . ۳۳
۶.۳ constraintهای ترتیبی روی خروجی متن . . . . . ۳۴
۷.۳ آموزش، داده و ارزیابی . . . . . ۳۵
۸.۳ baselineها و ablationها . . . . . ۳۵

**۴ جهت ۳: نمایش احتمالاتی درجه‌ها ۳۷**
۱.۴ انگیزه و شکاف پژوهشی . . . . . ۳۹
۲.۴ مدل von Mises–Fisher برای هر درجه . . . . . ۳۹
۳.۴ امتیازدهی: vMF mixture posterior . . . . . ۳۹
۴.۴ محاسبهٔ پایدار Bessel function . . . . . ۴۰
۵.۴ معماری . . . . . ۴۱
۶.۴ loss functionها . . . . . ۴۱
۷.۴ بهینه‌سازی . . . . . ۴۲
۸.۴ داده، ارزیابی و تأکید بر calibration . . . . . ۴۲
۹.۴ baselineها و ablationها . . . . . ۴۲

**metric موفقیت و جمع‌بندی ۴۵**

**واژه‌نامه ۴۶**

**منابع ۴۷**

# فهرست تصاویر


۱ چهار مدل پژوهش و ارتباط آن‌ها. هر سه جهت بر image branch، داده، protocol و metricهای مدل پایه بنا شده‌اند و فقط در نحوهٔ ساختن نمایش متنیِ درجه‌ها تفاوت دارند. . . . . ۲

۲ گردش کار کامل مدل پایه: (الف) image branch با LoRA و prompt learner رتبه‌ای OrdinalCLIP، (ب) cross-entropy و ranking-aware loss روی calibrated similarity با SMS و metricهای ارزیابی. . . . . ۴

۳ ایدهٔ مدل پایه در یک نگاه: سه جایی که ترتیب درجه‌ها وارد مدل می‌شود. . . . . ۵

۴ توزیع درجه‌ها در آموزش و آزمون DeepDRiD . . . . . ۶

۵ تقسیم داده. همهٔ تقسیم‌ها در سطح بیمار انجام می‌شوند تا هیچ بیماری هم‌زمان در آموزش و ارزیابی نباشد. ۸

۶ زنجیرهٔ preprocessing. مسیر پیوسته در آموزش و مسیر خط‌چین در ارزیابی به کار می‌رود. . . . . ۹

۷ معماری مدل پایه. blockهای CLIP frozen تغییر نمی‌کنند؛ فقط ماتریس‌های LoRA، context tokenها و سه base rank token آموخته می‌شوند. . . . . ۱۰

۸ LoRA block روی هر لایهٔ convolution (رابطهٔ ۱.۱). مسیر بالا frozen است و فقط $A$ و $B$ آموخته می‌شوند. ۱۱

۹ rank token interpolationها (رابطهٔ ۲.۱). هر rank token ترکیب وزن‌دار هر سه پایه است و وزن پایهٔ نزدیک‌تر بیشتر است (جدول ۴). . . . . ۱۲

۱۰ چرخهٔ SMS در هر epoch. statisticها در طول epoch ثابت‌اند و فقط در پایان epoch به‌روز می‌شوند. . . . ۱۳

۱۱ شکل unimodal که ranking-aware loss (رابطهٔ ۷.۱) تحمیل می‌کند: هر پیکان یک جملهٔ pairwise loss است که similarity درجهٔ نزدیک‌تر را از درجهٔ دورتر بیشتر می‌خواهد. . . . . ۱۴

۱۲ گردش کار یک اجرا. اجرای قطع‌شده از آخرین checkpoint ادامه می‌یابد و اجرای تکراری دوباره آموزش داده نمی‌شود. . . . . ۱۵

۱۳ چهار گروه metric و ورودی هر گروه. . . . . ۱۶

۱۴ protocol آزمایش‌های مدل پایه: regimeها و تکرارها، بهینه‌سازی، انتخاب مدل، اندازهٔ مدل، baselineها و ablationها. . . . . ۱۹

۱۵ گردش کار دو مرحله‌ای. اجرای تکراری یک configuration در هیچ notebookای دوباره آموزش داده نمی‌شود. ۱۹

۱۶ گردش کار کامل جهت ۱: بردارهای آزاد درجه که یک بار از جمله‌های بالینی مقداردهی می‌شوند، constraintهای ladder، path و anchor روی همان بردارها و geometric diagnostics هر epoch. . . . . ۲۱

۱۷ شکاف پژوهشی جهت ۱: ترکیب prototype آزاد (مانند CLAP) با constraint ترتیبی مستقیم. . . . . ۲۲

۱۸ معماری جهت ۱. text encoder فقط در initialisation به کار می‌رود و در آموزش و آزمون حذف می‌شود. . ۲۳

۱۹ سه گزینهٔ مقداردهی grade vectorها. . . . . ۲۴

۲۰ سه constraint هندسی روی grade vectorها. ladder ترتیب فاصله‌ها، مسیر شکل کلی و anchor پیوند با دانش زبانی را حفظ می‌کند. . . . . ۲۵

۲۱ یک گام بهینه‌سازی در جهت ۱. normalisation پس از هر گام بردارها را روی sphere نگه می‌دارد. . . . . ۲۶
۲۲ protocol آزمایش‌های جهت ۱. . . . . ۲۷
۲۳ گردش کار آزمایش‌های جهت ۱. . . . . ۲۸
۲۴ گردش کار کامل جهت ۲: توصیف‌های بالینی، LoRA روی $q$، $k$ و $v$ text encoder، prototypeها میانگین، similarity matrix توصیف‌ها $S^d$ و loss function با constraintهای ladder، description ordering و anchor. ۳۰
۲۵ شکاف پژوهشی جهت ۲. . . . . ۳۱
۲۶ معماری جهت ۲. LoRA متن و LoRA تصویر هم‌زمان آموخته می‌شوند. . . . . ۳۲
۲۷ ساختن prototype هر درجه از پنج توصیف. . . . . ۳۳
۲۸ attention block بازنویسی‌شده با LoRA روی q، k و v (رابطهٔ ۱.۳). . . . . ۳۴
۲۹ هدف description ordering (رابطهٔ ۳.۳). (الف) بدون این constraint، توصیف‌های درجه‌های همسایه روی هم می‌افتند. (ب) cross-entropy روی $S^d$ توصیف‌های هر درجه را دور prototype همان درجه جمع می‌کند و ranking-aware loss روی $S^d$ این خوشه‌ها را در امتداد محور درجه مرتب نگه می‌دارد. (ج) الگوی هدف ماتریس $S^d$: بیشترین similarity هر توصیف با درجهٔ خودش است و با فاصلهٔ درجه کاهش می‌یابد. . . . . ۳۴
۳۰ protocol آزمایش‌های جهت ۲. . . . . ۳۶
۳۱ گردش کار آزمایش‌های جهت ۲. . . . . ۳۶
۳۲ گردش کار کامل جهت ۳: mean directionها و concentrationهای trainable، vMF mixture posterior با محاسبهٔ پایدار Bessel function، loss function با concentration prior و تأکید بر metricهای calibration. ۳۸
۳۳ از نقطه به توزیع: درجه‌های مبهم‌تر (مانند ۱ تا ۳) می‌توانند concentration کمتر و پراکندگی بیشتری بیاموزند. ۳۹
۳۴ مسیر محاسبهٔ vMF logit. gradient از همهٔ مراحل تا $\ell_k$ عبور می‌کند. . . . . ۴۰
۳۵ معماری جهت ۳. هر درجه دو جزء trainable دارد: mean direction و concentration. . . . . ۴۱
۳۶ protocol آزمایش‌های جهت ۳. . . . . ۴۳
۳۷ گردش کار آزمایش‌های جهت ۳. . . . . ۴۴

# فهرست جداول


۱ چهار مدل در یک نگاه . . . . . ۲

۲ توزیع درجه‌ها در DeepDRiD (برچسب در سطح چشم) . . . . . ۶

۳ اندازهٔ بخش‌های داده در هر regime (سه seed) . . . . . ۷

۴ ماتریس وزن interpolation $W$ برای ۵ درجه و ۳ پایه . . . . . ۱۱

۵ تنظیمات آموزش مدل پایه . . . . . ۱۴

۶ baselineها در شاخهٔ master . . . . . ۱۷

۷ ablationها مدل پایه (هر کدام فقط در یک جزء با مدل کامل تفاوت دارد) . . . . . ۱۸

۸ آنچه در جهت ۱ تغییر می‌کند و آنچه ثابت می‌ماند . . . . . ۲۲

۹ جمله‌های بالینی initialisation (به زبان اصلی، همان‌گونه که به encoder داده می‌شوند) . . . . . ۲۴

۱۰ اجزای loss function جهت ۱ . . . . . ۲۶

۱۱ ablationها جهت ۱ . . . . . ۲۷

۱۲ آنچه در جهت ۲ تغییر می‌کند . . . . . ۳۱

۱۳ نمونهٔ توصیف‌های درجهٔ ۳ (شدید غیرتکثیری) . . . . . ۳۳

۱۴ ablationها جهت ۲ . . . . . ۳۵

۱۵ اجزای loss function جهت ۳ . . . . . ۴۲

۱۶ گروه‌های parameter در optimizer جهت ۳ . . . . . ۴۲

۱۷ ablationها جهت ۳ . . . . . ۴۳

۱۸ مقایسهٔ چهار مدل از نظر اجزا . . . . . ۴۵

۱۹ معادل‌های به‌کاررفته در سند . . . . . ۴۶

## مقدمه و نقشهٔ سند

رتینوپاتی دیابتی (Diabetic Retinopathy, DR) بر اساس مقیاس بین‌المللی ICDR در پنج درجه سنجیده می‌شود: بدون رتینوپاتی، خفیف، متوسط، شدید غیرتکثیری و تکثیری. این درجه‌ها ترتیب دارند. اشتباه گرفتن درجهٔ ۱ با درجهٔ ۲ از نظر بالینی بسیار کم‌هزینه‌تر از اشتباه گرفتن درجهٔ ۰ با درجهٔ ۴ است؛ با این حال بیشتر classifierها درجه‌ها را برچسب‌هایی مستقل می‌بینند و این ساختار را نادیده می‌گیرند. مشکل دوم کمبود داده است: برچسب‌زدن تصویر فوندوس به چشم‌پزشک نیاز دارد و در عمل گاهی فقط چند تصویر برای هر درجه در دسترس است.

مدل‌های بینایی و زبان مانند CLIP [۱] برای few-shot regime مناسب‌اند، چون دانش زبانی‌شان دربارهٔ مفاهیم را می‌توان با چند نمونه به یک مسئلهٔ تازه منتقل کرد. پرسش این پژوهش این است که ترتیب درجه‌ها را کجا و چگونه باید در این فضای مشترک وارد کرد تا مدل با تعداد بسیار کمی تصویر، درجه‌ها را نه‌تنها درست، بلکه با خطاهای «نزدیک» پیش‌بینی کند. metric اصلی موفقیت در همهٔ بخش‌ها Quadratic Weighted Kappa (QWK) است و در کنار آن بررسی می‌شود که در confusion matrix، خطاها با دور شدن از قطر اصلی کاهش یابند.

سند در چهار بخش اصلی تنظیم شده است. هر بخش یک مدل کامل است و برای خواندن مستقل نوشته شده؛ اجزای مشترک در بخش ۱ با جزئیات کامل آمده و در بخش‌های بعد، همراه با اعداد کلیدی، خلاصه شده است.

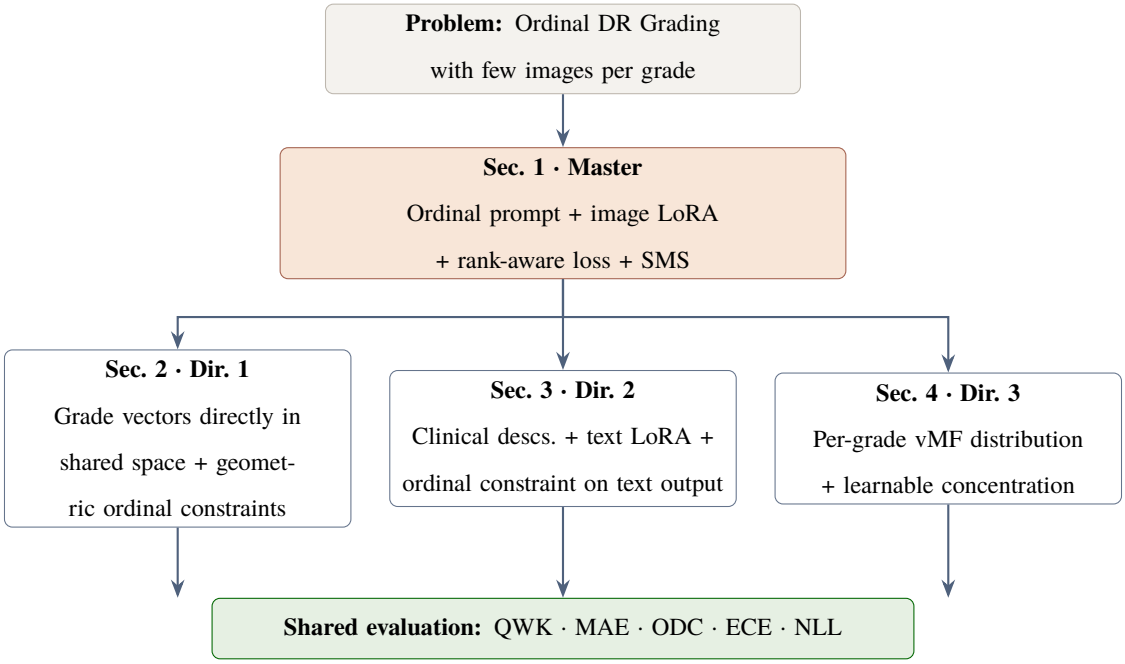
**پرسش‌های پژوهش**

۱. آیا ترتیب درجه‌ها، اگر در prompt، loss و similarity statistic با هم وارد شود، در QWK few-shot regime را بهبود می‌دهد؟ (بخش ۱)

۲. آیا اعمال ترتیب مستقیماً روی هندسهٔ prototypeها درجه‌ها، به‌جای ورودی text encoder، مؤثرتر است؟ (بخش ۲)

۳. آیا تطبیق خود text encoder با توصیف‌های بالینی، همراه با constraint ترتیبی روی خروجی آن، نمایش بهتری می‌سازد؟ (بخش ۳)

۴. آیا نمایش احتمالاتی درجه‌ها، با trainable concentration برای هر درجه، هم دقت ترتیبی و هم calibration را بهبود می‌دهد؟ (بخش ۴)



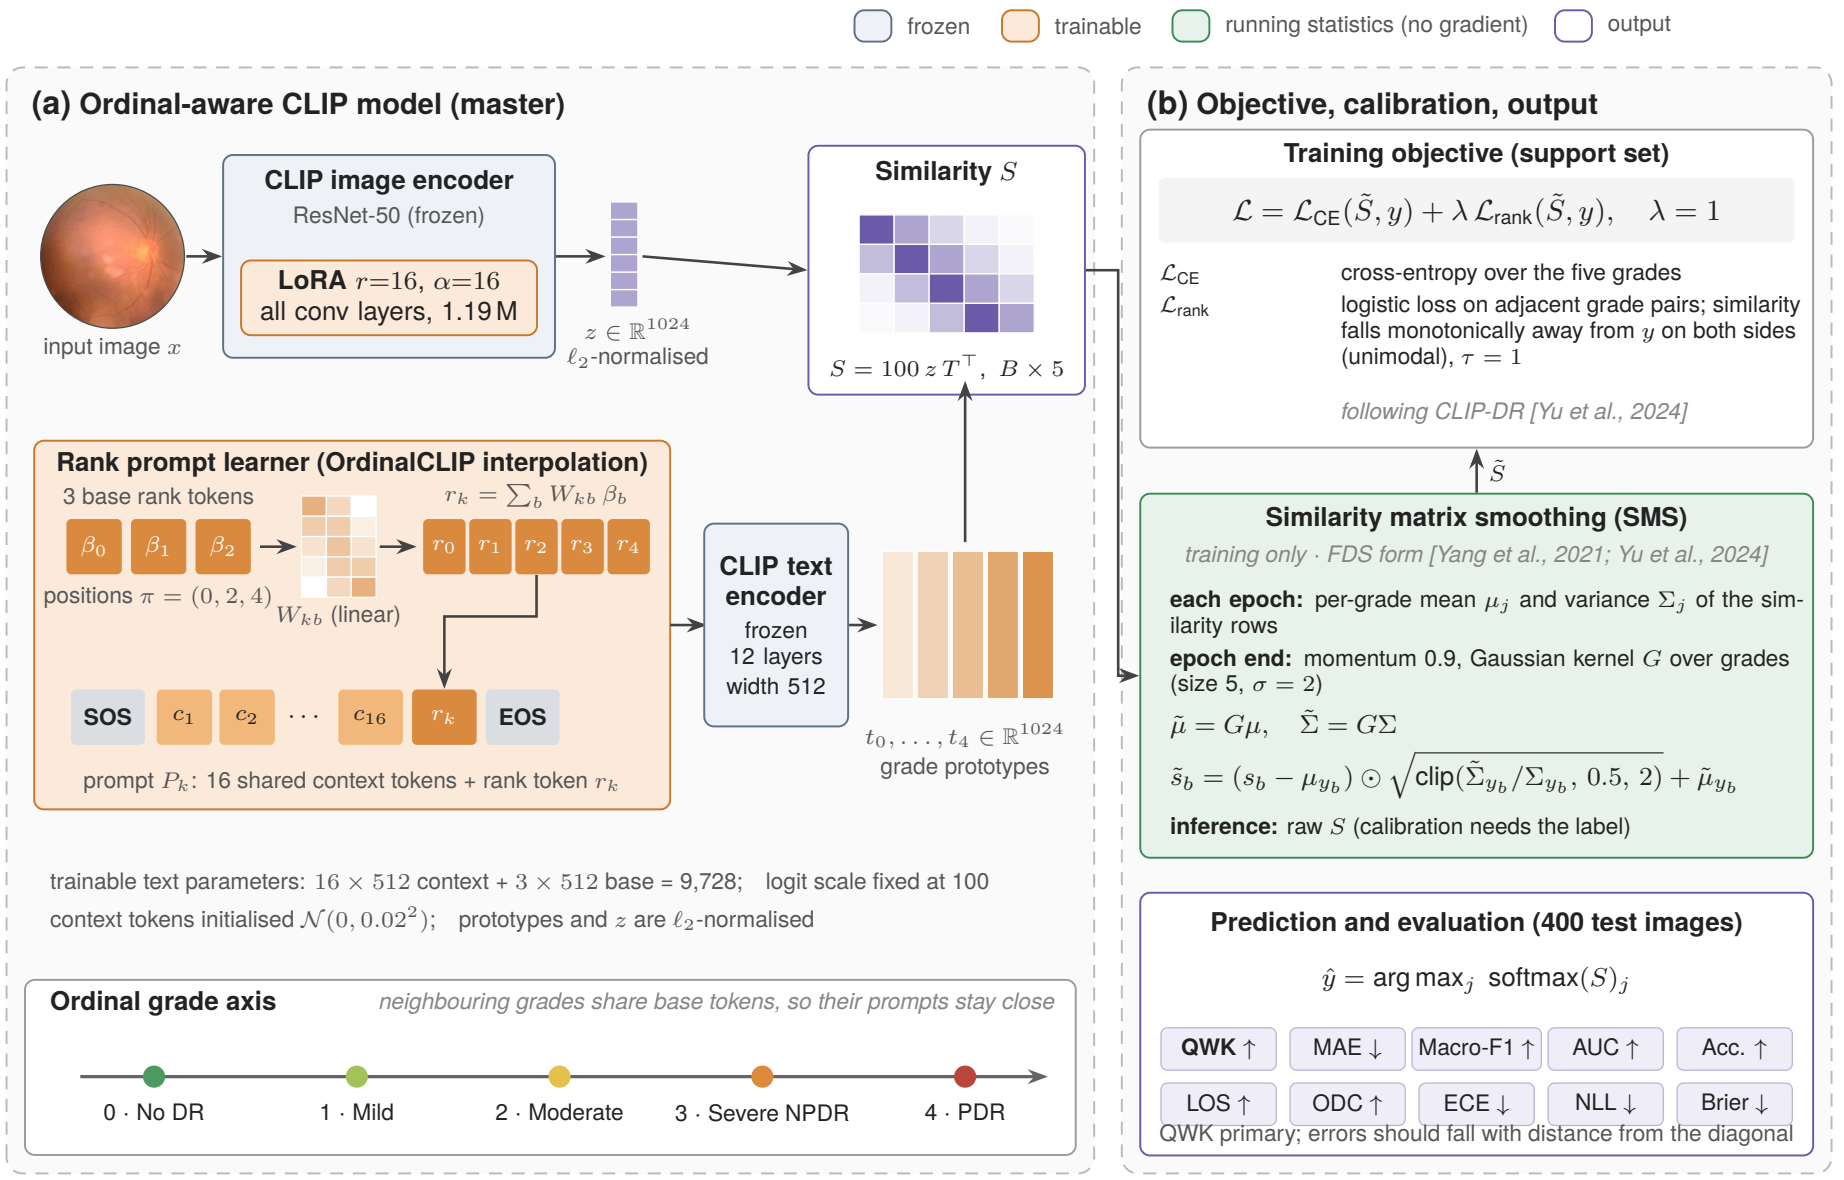

**شکل ۱:** چهار مدل پژوهش و ارتباط آن‌ها. هر سه جهت بر image branch، داده، protocol و metricهای مدل پایه بنا شده‌اند و فقط در نحوهٔ ساختن نمایش متنیِ درجه‌ها تفاوت دارند.

**جدول ۱:** چهار مدل در یک نگاه

| مدل | نمایش متنی درجه‌ها از کجا می‌آید | ترتیب کجا اعمال می‌شود | trainable parameter |
|---|---|---|---|
| مدل پایه | prompt با context tokenها و رتبهٔ learnable، از frozen text encoder | rank token interpolationها، ranking-aware loss، SMS | ۱,۱۹۸,۰۰۰ |
| جهت ۱ | پنج بردار آزاد در فضای مشترک، آغازشده از جمله‌های بالینی | constraintهای ladder، path و anchor روی خود بردارها | ۱,۱۹۳,۳۹۲ |
| جهت ۲ | میانگین ۵ توصیف بالینی برای هر درجه، از text encoder تطبیق‌یافته با LoRA | ladder روی prototypeها، description anchor، ordering | ۱,۲۶۲,۰۰۰ |
| جهت ۳ | von Mises–Fisher distribution برای هر درجه: mean direction و concentration | ladder و anchor روی میانگین‌ها، overlap توزیع‌ها | ۱,۱۹۳,۳۹۷ |

# ۱ مدل پایه (شاخهٔ master)

شکل ۲ کل گردش کار مدل پایه را در یک نگاه نشان می‌دهد: blockهای مدل (الف) و loss function، calibration و ارزیابی (ب). تقسیم داده در بخش ۲.۱ و protocol آزمایش‌ها در شکل ۱۴ جداگانه آمده‌اند و زیربخش‌های این فصل هر block را شرح می‌دهند.




**شکل ۲:** گردش کار کامل مدل پایه: (الف) image branch با LoRA و prompt learner رتبه‌ای OrdinalCLIP، (ب) cross-entropy و ranking-aware loss روی calibrated similarity با SMS و metricهای ارزیابی.

## ۱.۱ مسئله و ایدهٔ مدل

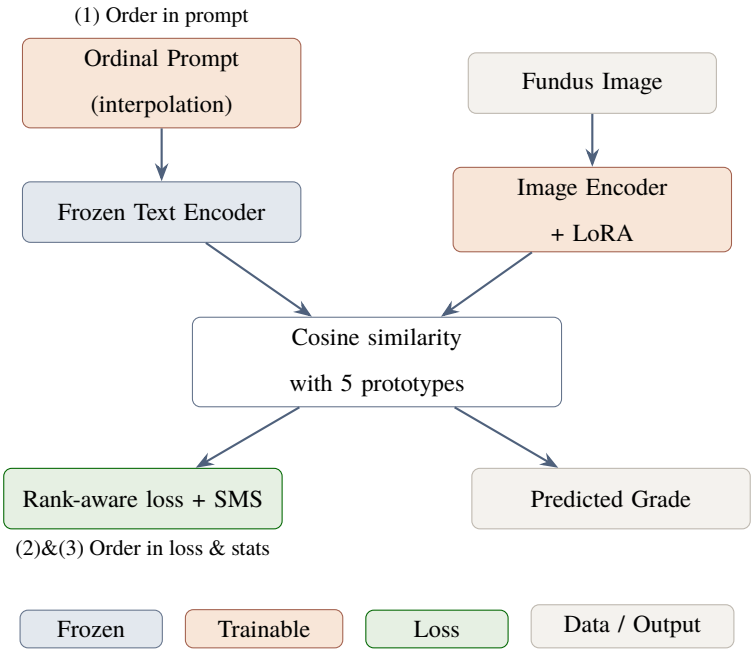
مدل پایه CLIP را بدون تغییر وزن‌های اصلی‌اش برای درجه‌بندی DR تطبیق می‌دهد. برای هر درجه یک جملهٔ learnable ساخته می‌شود که از CLIP frozen text encoder می‌گذرد و یک بردار prototype برای آن درجه می‌سازد. تصویر هم از image encoder CLIP، که با low-rank adaptation اندکی تنظیم شده، عبور می‌کند. درجهٔ پیش‌بینی‌شده prototypeای است که بیشترین cosine similarity را با بردار تصویر دارد.

ترتیب درجه‌ها در سه جا وارد مدل می‌شود:

۱. **در prompt parameterisation:** rank tokenها از interpolation سه توکن پایه ساخته می‌شوند، پس درجه‌های مجاور توکن‌های شبیه‌تری دارند (OrdinalCLIP [۲]).

۲. **در loss function:** ranking-aware loss (CLIP-DR [۳]) مدل را وادار می‌کند similarity تصویر با درجه‌ها با دور شدن از درجهٔ درست کاهش یابد.

۳. **در similarity statistic:** similarity statistic (SMS) Similarity Matrix Smoothing هر درجه را به درجه‌های همسایه نزدیک می‌کند.




**شکل ۳:** ایدهٔ مدل پایه در یک نگاه: سه جایی که ترتیب درجه‌ها وارد مدل می‌شود.

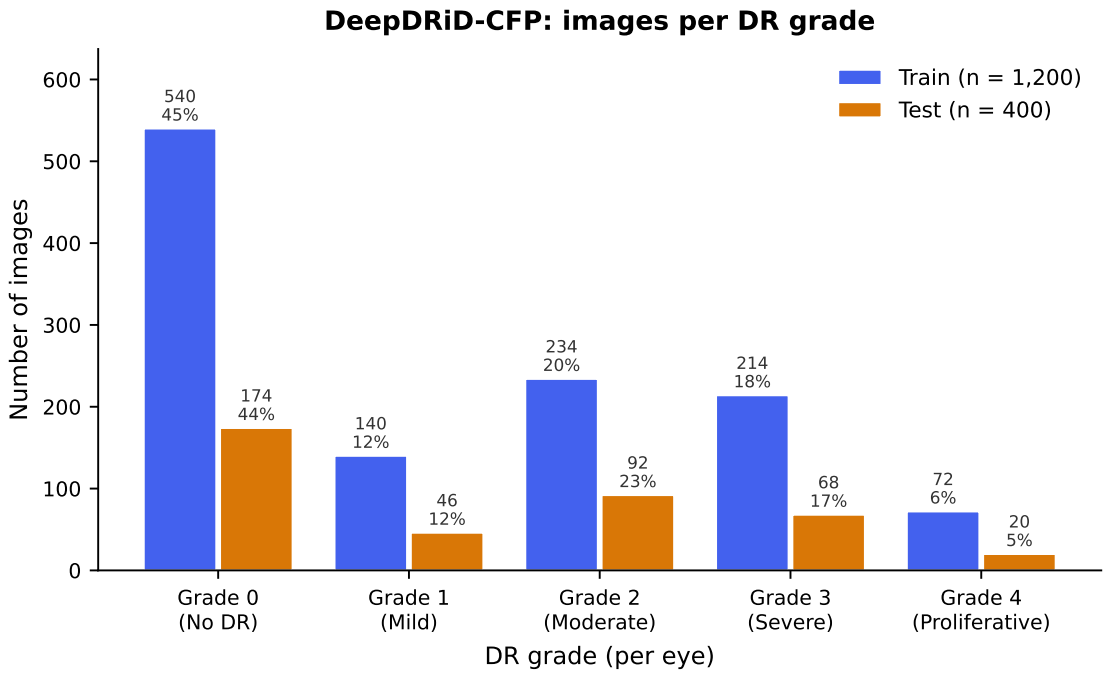
## ۲.۱ داده و few-shot protocol

دادهٔ اصلی، تصاویر فوندوس معمولی مجموعهٔ DeepDRiD [۱۳] است: ۱,۶۰۰ تصویر از ۴۰۰ بیمار، برای هر چشم دو تصویر. برچسب هر تصویر درجهٔ همان چشم است، نه درجهٔ کلی بیمار. این تمایز مهم است: درجهٔ بیمار برابر بدترین چشم اوست و استفاده از آن به‌جای درجهٔ چشم، ۳۵۸ تصویر را ۱ تا ۴ درجه بالاتر برچسب می‌زد. ۳۰۰ بیمار (۱,۲۰۰ تصویر) training set و ۱۰۰ بیمار دیگر (۴۰۰ تصویر، همان مجموعهٔ validation رسمی DeepDRiD) test set را می‌سازند و هیچ بیماری در هر دو

نیست.

**جدول ۲:** توزیع درجه‌ها در DeepDRiD (برچسب در سطح چشم)

| بخش | درجهٔ ۰ | درجهٔ ۱ | درجهٔ ۲ | درجهٔ ۳ | درجهٔ ۴ | جمع |
|---|---|---|---|---|---|---|
| آموزش | ۵۴۰ | ۱۴۰ | ۲۳۴ | ۲۱۴ | ۷۲ | ۱,۲۰۰ |
| آزمون | ۱۷۴ | ۴۶ | ۹۲ | ۶۸ | ۲۰ | ۴۰۰ |




**شکل ۴:** توزیع درجه‌ها در مجموعه‌های آموزش و آزمون DeepDRiD با برچسب سطح چشم (خروجی notebook DeepDRiD_FewShot_DR_fixed). نسبت درجه‌ها در دو بخش تقریباً یکسان است و درجهٔ ۴ با ۶ درصد few-shotترین درجه است.

در $k$-shot regime، از هر درجه $k$ تصویر آموزشی به‌عنوان support set برداشته می‌شود و مقدارهای ۱، ۲، ۴، ۸، ۱۶ و ۳۲ برای $k$ بررسی می‌شوند. هر آزمایش با سه seed تصادفی تکرار و میانگین و standard deviation گزارش می‌شود. سه نکتهٔ طراحی، نتیجه را منصفانه نگه می‌دارد:

۱. **supportهای تودرتو.** 8-shot support همهٔ تصاویر 4-shot support را در بر دارد، پس منحنی عملکرد بر حسب $k$ کمتر noise دارد.

۲. **query جدا در سطح بیمار.** query set که برای early stopping و انتخاب checkpoint به کار می‌رود، فقط شامل بیمارانی است که هیچ تصویری در support ندارند؛ چون هر بیمار چهار تصویر دارد، بدون این constraint تصویر چشم دیگر همان بیمار وارد ارزیابی می‌شد.

۳. **پوشش بیماران متفاوت.** در هنگام انتخاب تصاویر support، تصاویر بیماران تکراری در اولویت آخر قرار می‌گیرند تا support تا حد ممکن بیماران متفاوت را پوشش دهد.

دو حالت مرزی هم ارزیابی می‌شود. در حالت zero-shot ($k = 0$) هیچ آموزشی انجام نمی‌شود و مدل با وزن‌های اولیه آزموده می‌شود. در حالت full data ($k = -1$) کل training set استفاده می‌شود، جز ۲۰ درصد بیماران (۶۰ بیمار، ۲۴۰ تصویر) که برای validation کنار گذاشته می‌شوند؛ این holdout بر اساس بیمار و به تفکیک بدترین درجهٔ هر بیمار انجام می‌شود. test set در هیچ حالتی برای انتخاب مدل استفاده نمی‌شود.

### ۱.۲.۱ راهبرد تقسیم برای هر regime

تقسیم هر regime از سه مرحلهٔ ثابت ساخته می‌شود و همهٔ آن‌ها در سطح بیمار انجام می‌شوند:

۱. **ترتیب نمونه‌گیری هر درجه.** برای هر درجه و هر seed، تصاویر آموزشی آن درجه یک بار با مولد تصادفیِ وابسته به (seed، درجه) مرتب می‌شوند. در این ترتیب، اولین تصویر هر بیمار پیش از تصویر دوم هر بیماری می‌آید؛ پس تا وقتی بیمار تازه‌ای در آن درجه باقی است، تصویر تکراری از یک بیمار انتخاب نمی‌شود.

۲. **support.** $k$-shot support همان $k$ تصویر اول این ترتیب در هر درجه است، یعنی $5k$ تصویر. چون ترتیب به $k$ وابسته نیست، supportها تودرتو هستند و برای هر سه seed بررسی شده است که support هر $k$ زیرمجموعهٔ support $2k$ است.

۳. **query.** همهٔ تصاویرِ بیمارانی که حتی یک تصویر در support دارند از query حذف می‌شوند و بقیهٔ تصاویر آموزش، query را می‌سازند. به همین دلیل اندازهٔ query از $1200 - 5k$ کمتر است: هر بیمار support چهار تصویرش را از query بیرون می‌برد.

test set (۴۰۰ تصویر از ۱۰۰ بیمار) در همهٔ regimeها یکسان است و فقط یک بار، با بهترین checkpoint، ارزیابی می‌شود. جدول ۳ اندازهٔ هر بخش را برای همهٔ regimeها نشان می‌دهد؛ اعداد از فایل‌های تقسیم واقعی شمرده شده‌اند و جایی که بین سه seed تفاوت دارند، بازهٔ آن‌ها آمده است.

**جدول ۳:** اندازهٔ بخش‌های داده در هر regime (سه seed)

| regime | تصاویر آموزش | بیماران آموزش | تصاویر validation | بیماران validation | نقش validation |
|---|---|---|---|---|---|
| zero-shot ($k = 0$) | — | — | — | — | بدون آموزش |
| $k = 1$ | ۵ | ۵ | ۱,۱۸۰ | ۲۹۵ | query |
| $k = 2$ | ۱۰ | ۱۰ | ۱,۱۶۰ | ۲۹۰ | query |
| $k = 4$ | ۲۰ | ۲۰ | ۱,۱۲۰ | ۲۸۰ | query |
| $k = 8$ | ۴۰ | ۳۹ | ۱,۰۴۴ | ۲۶۱ | query |
| $k = 16$ | ۸۰ | ۷۶ تا ۷۸ | ۸۸۸ تا ۸۹۶ | ۲۲۲ تا ۲۲۴ | query |
| $k = 32$ | ۱۶۰ | ۱۴۱ تا ۱۴۵ | ۶۲۰ تا ۶۳۶ | ۱۵۵ تا ۱۵۹ | query |
| full data ($k = -1$) | ۹۶۰ | ۲۴۰ | ۲۴۰ | ۶۰ | ۲۰٪ holdout بیماران |

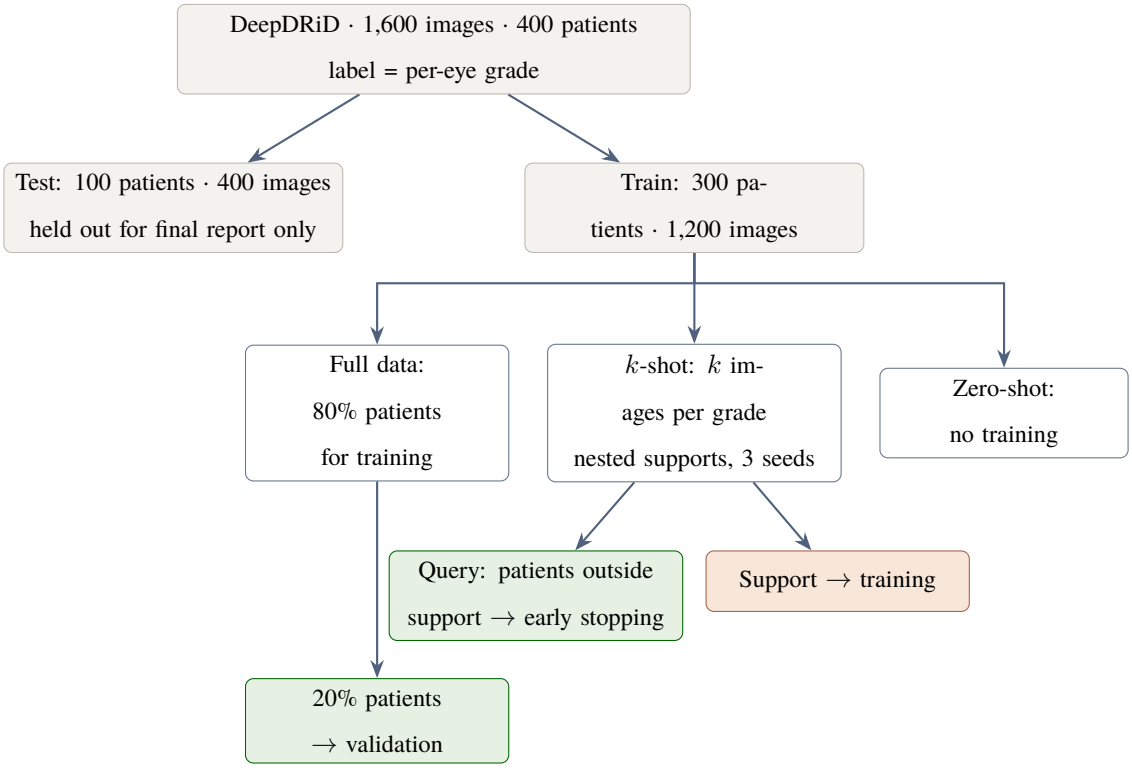
نکته‌های هر regime:

- **zero-shot.** هیچ تصویر آموزشی دیده نمی‌شود و مدل با prompt اولیه روی ۴۰۰ تصویر آزمون سنجیده می‌شود. این

regime سهم دانش اولیهٔ CLIP را جدا می‌کند.

- **۱ تا ۴ نمونه.** همهٔ تصاویر support از بیماران متفاوت‌اند (۵، ۱۰ و ۲۰ بیمار) و query تقریباً کل بقیهٔ دادهٔ آموزش است. در این regimeها SMS در 1-shot اثری ندارد، چون variance هر درجه صفر است.
- **۸ و ۱۶ نمونه.** درون هر درجه همهٔ تصاویر support از بیماران متفاوت‌اند، اما یک بیمار ممکن است با یک چشم در یک درجه و با چشم دیگر در درجهٔ دیگری انتخاب شود؛ به همین دلیل تعداد بیماران support (۳۹ و ۷۶ تا ۷۸) کمی کمتر از $5k$ است.
- **۳۲ نمونه.** support ۱۶۰ تصویر از ۱۴۱ تا ۱۴۵ بیمار دارد و ۳۲ تصویر از ۷۲ تصویر درجهٔ ۴ (از ۳۰ بیمار) را مصرف می‌کند؛ query به ۶۲۰ تا ۶۳۶ تصویر کاهش می‌یابد ولی هنوز همهٔ درجه‌ها را پوشش می‌دهد.
- **full data.** به‌جای support و query، ۲۰ درصد بیماران هر لایه (بیماران با بدترین درجهٔ یکسان) با seed اجرا کنار گذاشته می‌شوند: ۹۶۰ تصویر از ۲۴۰ بیمار برای آموزش و ۲۴۰ تصویر از ۶۰ بیمار برای validation.

seedها supportهای تقریباً جدا از هم می‌سازند (برای نمونه seed ۱ و ۲ 8-shot support فقط یک تصویر مشترک دارند)، پس standard deviation سه seed تغییرپذیری انتخاب support را نشان می‌دهد.

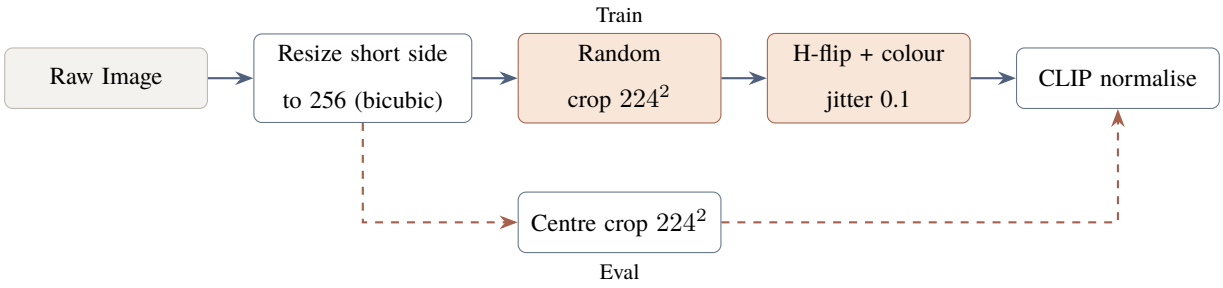



**شکل ۵:** تقسیم داده. همهٔ تقسیم‌ها در سطح بیمار انجام می‌شوند تا هیچ بیماری هم‌زمان در آموزش و ارزیابی نباشد.

## ۳.۱ preprocessing و data augmentation

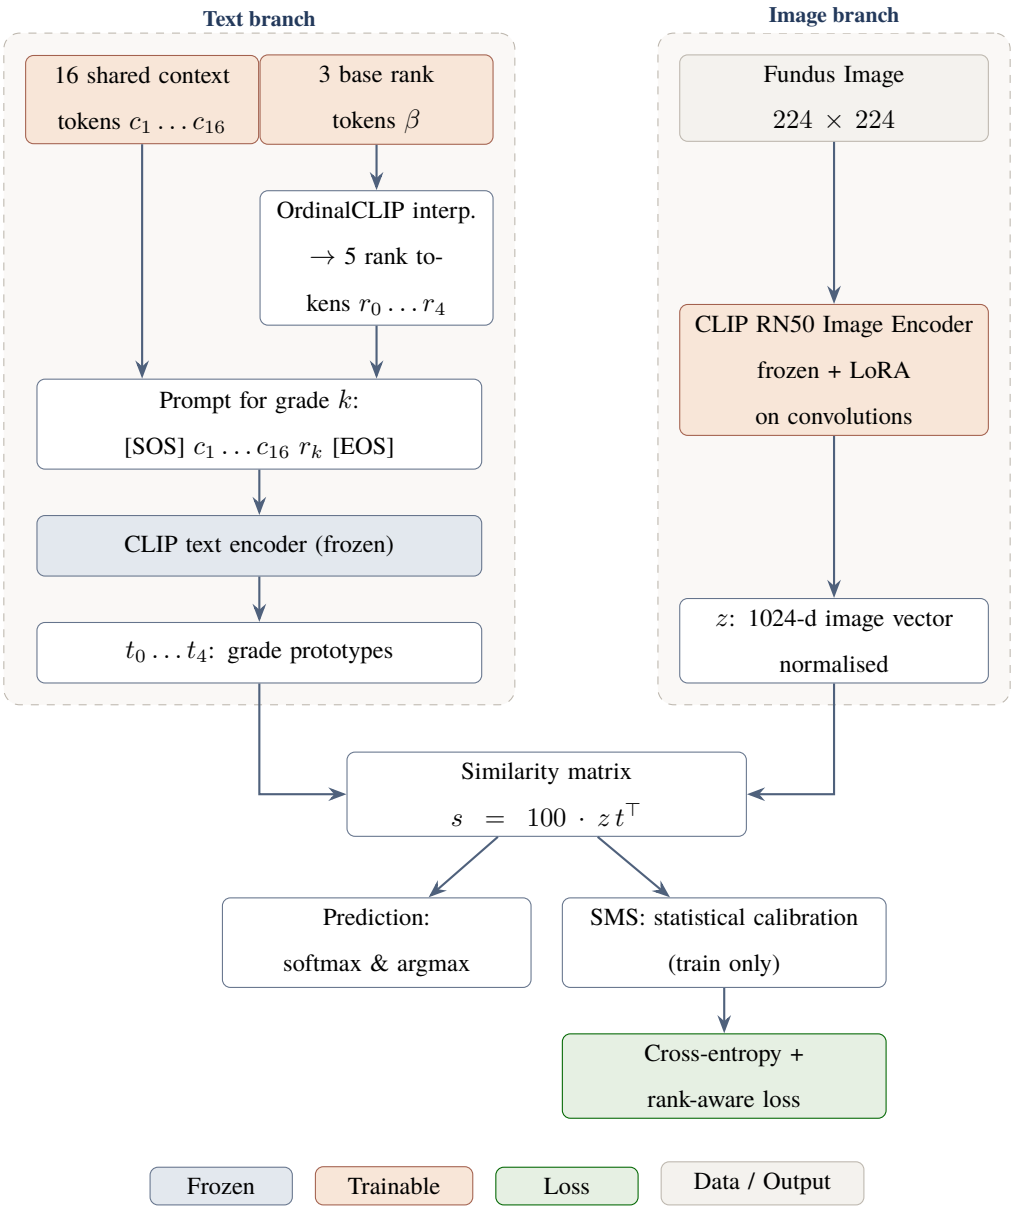
در آموزش، ضلع کوتاه‌تر تصویر با bicubic interpolation به ۲۵۶ پیکسل می‌رسد، سپس برشی تصادفی به اندازهٔ $224 \times 224$، random horizontal flip و slight colour jitter (روشنایی، کنتراست و اشباع، هر کدام تا ۰/۱) اعمال و تصویر با میانگین و

CLIP standard deviation نرمال می‌شود. در ارزیابی به‌جای random crop، centre crop به کار می‌رود و data augmentationای در کار نیست. baseline preprocessingها در دستور رسمی خودشان (تغییر اندازه به مربع ۲۵۶، برش، flipping و normalisation ImageNet) فقط در configurationهای «official» استفاده می‌شود.




**شکل ۶:** زنجیرهٔ preprocessing. مسیر پیوسته در آموزش و مسیر خط‌چین در ارزیابی به کار می‌رود.

## ۴.۱ معماری و blockهای مدل



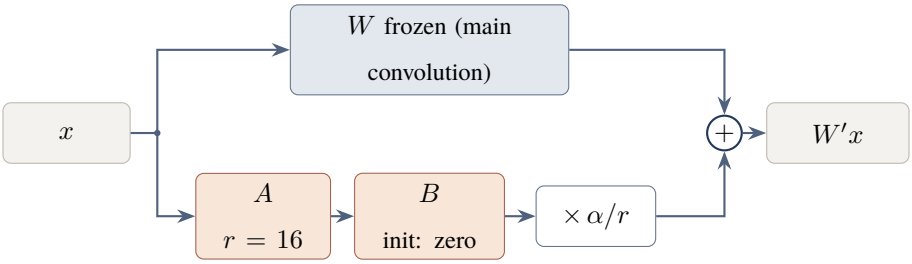

**شکل ۷:** معماری مدل پایه. blockهای CLIP frozen تغییر نمی‌کنند؛ فقط ماتریس‌های LoRA، context tokenها و سه base rank token آموخته می‌شوند.

### ۱.۴.۱ image branch: CLIP RN50 با LoRA

image encoder، شبکهٔ ResNet-50 مدل CLIP است که بردار ۱۰۲۴ـبعدی تولید می‌کند. وزن‌های آن frozen می‌مانند و روی همهٔ لایه‌های convolution (لایه‌های ورودی و سه convolution هر bottleneck block) low-rank adaptation (LoRA [۷]) اضافه می‌شود. این روش به‌جای تغییر وزن $W$، حاصل‌ضرب دو ماتریس کوچک را به آن می‌افزاید:

$$W' = W + \frac{\alpha}{r} BA, \qquad r = 16,\ \alpha = 16,\ B_{\text{init}} = 0 \tag{۱.۱}$$

با $B = 0$ در آغاز، مدل دقیقاً همان CLIP اولیه است. LoRA dropout برابر ۰/۱ است و کل parameterهای آن ۱,۱۸۸,۲۷۲ است. خروجی encoder به طول واحد نرمال می‌شود: $z = f_\theta(x)/\|f_\theta(x)\|$.




**شکل ۸:** LoRA block روی هر لایهٔ convolution (رابطهٔ ۱.۱). مسیر بالا frozen است و فقط $A$ و $B$ آموخته می‌شوند.

### ۲.۴.۱ text branch: prompt رتبه‌ای با OrdinalCLIP interpolation

برای هر درجهٔ $k$ یک دنبالهٔ توکن ساخته می‌شود: نشانهٔ آغاز، ۱۶ context token مشترک $c_1, \ldots, c_{16}$، یک rank token $r_k$ و نشانهٔ پایان. context tokenها بین همهٔ درجه‌ها مشترک‌اند و با توزیع نرمال با standard deviation ۰/۰۲ آغاز می‌شوند. rank tokenها آزاد نیستند: از سه بردار پایهٔ learnable $\beta_0, \beta_1, \beta_2$ که در موقعیت‌های $\pi = (0, 2, 4)$ روی محور درجه قرار گرفته‌اند، با وزن‌دهی خطی OrdinalCLIP ساخته می‌شوند:

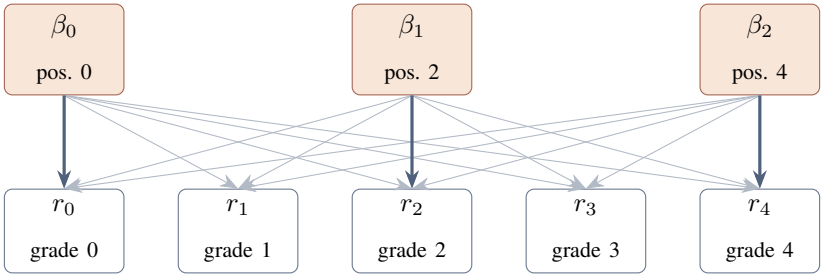
$$r_k = \sum_{b=0}^{2} W_{kb}\, \beta_b, \qquad W_{kb} = \frac{1 - |k - \pi_b|/(K-1)}{\sum_{b'} \left(1 - |k - \pi_{b'}|/(K-1)\right)} \tag{۲.۱}$$

در این وزن‌دهی هر درجه آمیزه‌ای از هر سه پایه است، نه فقط دو پایهٔ نزدیک؛ بنابراین درجه‌های مجاور توکن‌های شبیه به هم دارند و ترتیب در خود parameterisation نهفته است. این وزن‌ها با کد رسمی OrdinalCLIP مقایسه و یکسان یافته شده‌اند.

**جدول ۴:** ماتریس وزن interpolation $W$ برای ۵ درجه و ۳ پایه

| درجه | $\beta_0$ | $\beta_1$ | $\beta_2$ |
|---|---|---|---|
| ۰ | ۰/۶۶۷ | ۰/۳۳۳ | ۰ |
| ۱ | ۰/۴۲۹ | ۰/۴۲۹ | ۰/۱۴۳ |
| ۲ | ۰/۲۵۰ | ۰/۵۰۰ | ۰/۲۵۰ |
| ۳ | ۰/۱۴۳ | ۰/۴۲۹ | ۰/۴۲۹ |
| ۴ | ۰ | ۰/۳۳۳ | ۰/۶۶۷ |

دنبالهٔ هر درجه از CLIP frozen text encoder (Transformer ۱۲ لایه با پهنای ۵۱۲) عبور می‌کند و خروجیِ موقعیت نشانهٔ پایان پس از تصویر خطی، prototype آن درجه است: $t_k = g(p_k)/\|g(p_k)\|$. parameterهای trainable این شاخه $16 \times 512$ برای بافت و $3 \times 512$ برای پایه‌ها، در مجموع ۹,۷۲۸ است.




**شکل ۹:** rank token interpolationها (رابطهٔ ۲.۱). هر rank token ترکیب وزن‌دار هر سه پایه است و وزن پایهٔ نزدیک‌تر بیشتر است (جدول ۴).

### ۳.۴.۱ similarity matrix و پیش‌بینی

similarity تصویر $b$ با درجهٔ $k$ ضرب داخلی دو بردار نرمال‌شده در CLIP logit scale است. این مقیاس در مقدار ۱۰۰ ثابت نگه داشته می‌شود، همان‌طور که در OrdinalCLIP و CLIP-DR:

$$s_{bk} = \tau^{-1}\, z_b^{\top} t_k, \qquad \tau^{-1} = 100, \qquad p_{bk} = \frac{\exp(s_{bk})}{\sum_j \exp(s_{bj})}, \qquad \hat{y}_b = \arg\max_k p_{bk} \tag{۳.۱}$$

### ۴.۴.۱ (SMS) Similarity Matrix Smoothing

این جزء از CLIP-DR [۳] گرفته شده و صورت دقیق آن Feature Distribution Smoothing (FDS) [۸] است که روی بردار ۵-بعدی similarity هر تصویر اجرا می‌شود. ایده این است که similarity statistic تصاویر یک درجه نباید از درجه‌های همسایه‌اش فاصلهٔ زیادی داشته باشد. برای هر درجهٔ $j$، در طول یک epoch میانگین $\mu_j$ و variance $\Sigma_j$ بردارهای similarity تصاویر آن درجه، به تفکیک هر بُعد، جمع‌آوری می‌شود. این statistic‌ها با momentum $m = 0.9$ بین epochها به‌روزرسانی و سپس با Gaussian kernel روی محور درجه هموار می‌شوند:

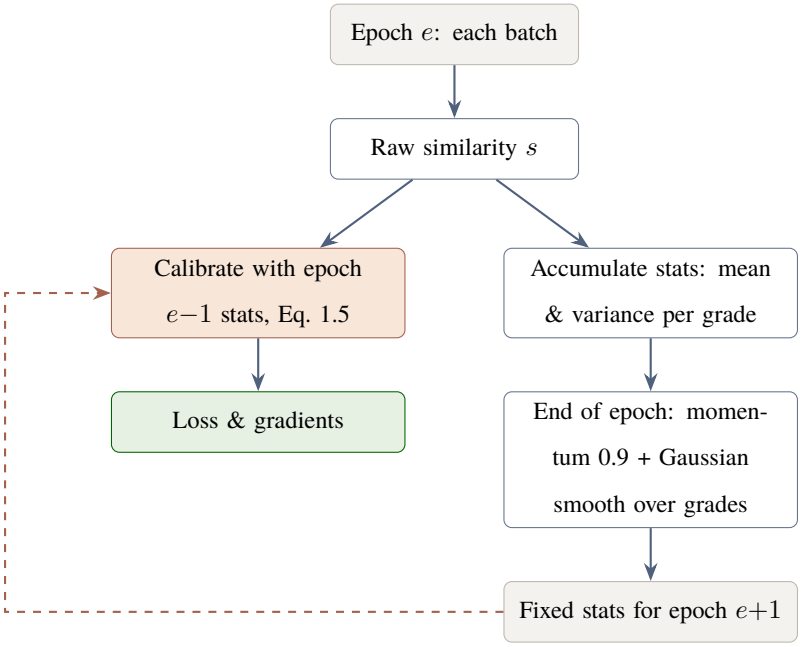
$$\tilde{\mu}_j = \sum_{j'} g(j-j')\,\mu_{j'}, \qquad \tilde{\Sigma}_j = \sum_{j'} g(j-j')\,\Sigma_{j'}, \qquad g = (0.186,\ 0.205,\ 0.217,\ 0.205,\ 0.186) \tag{۴.۱}$$

kernel اندازهٔ ۵ و standard deviation ۲ دارد و در لبه‌های محور درجه، بازتابی گسترش می‌یابد. در epoch بعد، similarity هر تصویر آموزشی با statistic درجهٔ خودش بازمقیاس می‌شود و loss روی همین calibrated similarity محاسبه می‌شود:

$$\tilde{s}_b = \left(s_b - \mu_{y_b}\right) \odot \sqrt{\mathrm{clip}\left(\tilde{\Sigma}_{y_b}/\Sigma_{y_b},\ 0.5,\ 2\right)} + \tilde{\mu}_{y_b} \tag{۵.۱}$$

چون این calibration به درجهٔ واقعی نیاز دارد، فقط در آموزش اعمال می‌شود و در آزمون similarity خام به کار می‌رود. در حالت 1-shot، هر درجه در هر epoch فقط یک تصویر دارد و variance صفر است؛ در این حالت SMS عملاً هیچ اثری ندارد.

**نکته برای گزارش.** در کد منتشرشدهٔ CLIP-DR فراخوانی‌های SMS غیرفعال (توضیح‌کد) شده‌اند، هرچند مقاله اثر آن را گزارش می‌کند. به همین دلیل نسخهٔ CLIP-DR matched در این پژوهش بدون SMS اجرا می‌شود.




**شکل ۱۰:** چرخهٔ SMS در هر epoch. statisticها در طول epoch ثابت‌اند و فقط در پایان epoch به‌روز می‌شوند.

## ۵.۱ loss functionها

loss کل مدل پایه دو جزء دارد که هر دو روی calibrated similarity $\tilde{s}$ محاسبه می‌شوند:

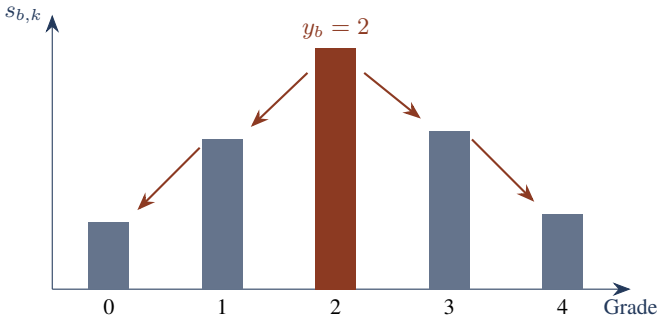
$$\mathcal{L} = \mathcal{L}_{\text{CE}}(\tilde{s}, y) + \lambda_{\text{rank}}\, \mathcal{L}_{\text{rank}}(\tilde{s}, y), \qquad \lambda_{\text{rank}} = 1 \tag{۶.۱}$$

**cross-entropy.** loss استاندارد طبقه‌بندی که تصویر را به prototype درجهٔ درست نزدیک و از بقیه دور می‌کند: $\mathcal{L}_{\text{CE}} = -\frac{1}{B}\sum_b \log p_{b,y_b}$. این loss به تنهایی ترتیب را نمی‌بیند؛ پیش‌بینی درجهٔ ۴ برای تصویر درجهٔ ۰ همان‌قدر جریمه می‌شود که پیش‌بینی درجهٔ ۱.

**ranking-aware loss.** این loss از CLIP-DR است و شکل «unimodal» را تحمیل می‌کند: similarity تصویر با درجه‌ها باید از درجهٔ درست به سمت هر دو طرف به‌طور یکنواخت کاهش یابد. برای هر جفت درجهٔ مجاور در سمت راست و چپ درجهٔ درست، logistic pairwise loss اعمال می‌شود:

$$\mathcal{L}_{\text{rank}} = \frac{1}{B}\sum_b \left[ \sum_{r=y_b}^{K-2} -\log\sigma\!\left(\frac{s_{b,r} - s_{b,r+1}}{\tau_r}\right) + \sum_{r=1}^{y_b} -\log\sigma\!\left(\frac{s_{b,r} - s_{b,r-1}}{\tau_r}\right) \right], \qquad \tau_r = 1 \tag{۷.۱}$$

این صورت همان رابطهٔ مقاله است. کد CLIP-DR همین constraint را با cross-entropy روی بردارهایی پیاده می‌کند که درایه‌های غیرمرتبطشان صفر است و فقط سه گام فاصله را می‌پوشاند؛ صورت بالا همهٔ جفت‌ها را بدون آن درایه‌های صفر در بر دارد.



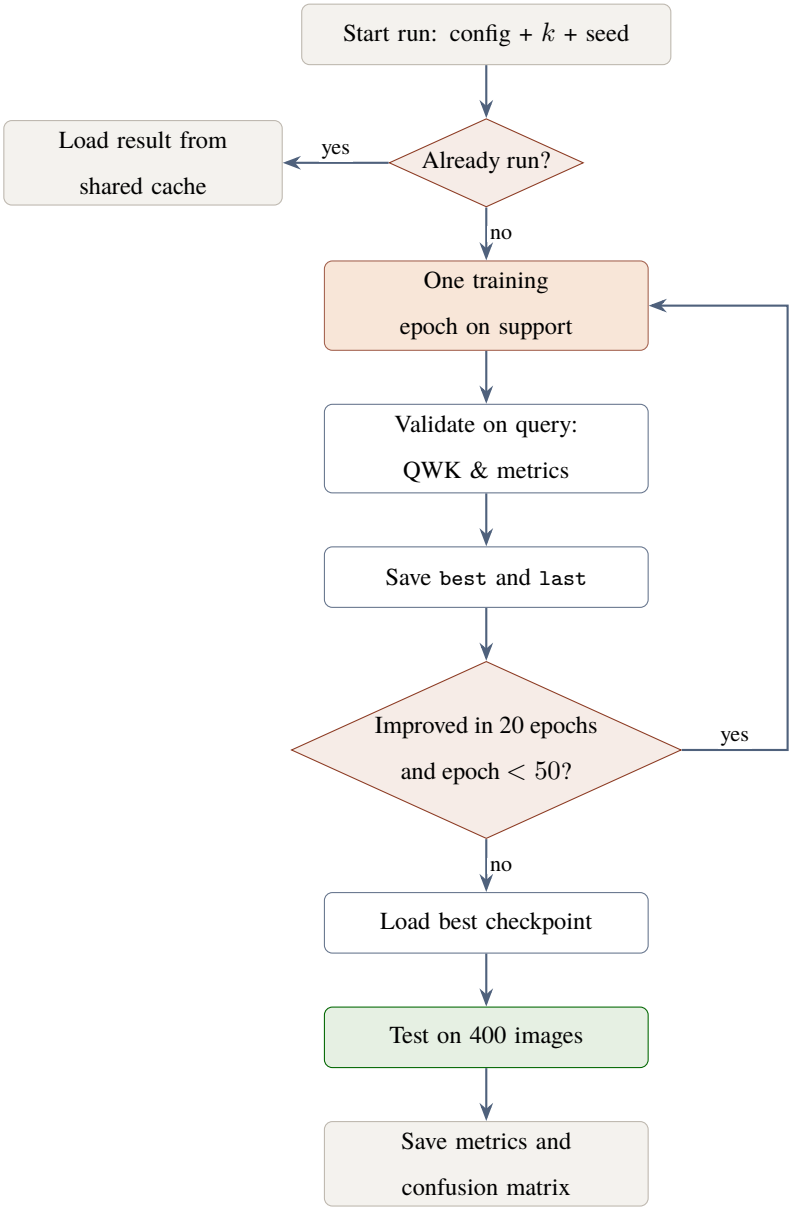

**شکل ۱۱:** شکل unimodal که ranking-aware loss (رابطهٔ ۷.۱) تحمیل می‌کند: هر پیکان یک جملهٔ pairwise loss است که similarity درجهٔ نزدیک‌تر را از درجهٔ دورتر بیشتر می‌خواهد.

**اجزای کنارگذاشته‌شده.** RankFormer و distance-weighted pairwise loss، که از مقالهٔ L2RCLIP [۴] الهام گرفته‌اند، جزو مدل پایه نیستند. repository رسمی L2RCLIP کد مدل، کد آموزش و وزن‌های آموخته را منتشر نکرده است، پس درستی پیاده‌سازی را فقط می‌توان با متن مقاله سنجید. این دو جزء به‌صورت configurationهای جداگانه نگه داشته شده‌اند و در بخش ۸.۱ شرح داده می‌شوند.

## ۶.۱ آموزش و بهینه‌سازی

**جدول ۵:** تنظیمات آموزش مدل پایه

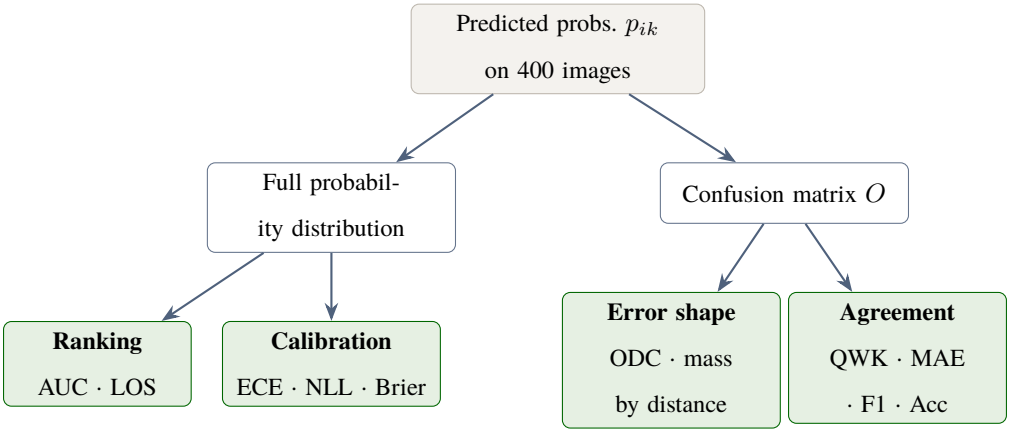
| مؤلفه | مقدار |
|---|---|
| optimizer | AdamW، learning rate $10^{-4}$، weight decay $10^{-4}$ |
| learning rate schedule | linear warm-up ۵ epoch و سپس cosine decay |
| تعداد epoch | ۵۰ (یکسان برای همهٔ مدل‌های matched) |
| batch size | آموزش: کمینهٔ اندازهٔ support و ۳۲؛ ارزیابی: ۳۲ |
| early stopping | صبر ۲۰ epoch روی QWK query set |
| checkpointها | بهترین مدل بر اساس QWK query و آخرین epoch، پس از هر epoch؛ آزمون با بهترین |
| دقت عددی و پایداری | آمیختهٔ bf16، gradient clipping با نُرم ۱ |
| parameterهای frozen | همهٔ CLIP، از جمله token embedding table و logit scale |
| parameterهای trainable | LoRA تصویر ۱,۱۸۸,۲۷۲ + توکن‌ها ۹,۷۲۸ = ۱,۱۹۸,۰۰۰ |




**شکل ۱۲:** گردش کار یک اجرا. اجرای قطع‌شده از آخرین checkpoint ادامه می‌یابد و اجرای تکراری دوباره آموزش داده نمی‌شود.

## ۷.۱ ارزیابی و metricها

همهٔ metricها روی ۴۰۰ تصویر آزمون و با پیش‌بینی بیشینه‌احتمال محاسبه می‌شوند. metric اصلی QWK است و دو metric ترتیبی ODC و error mass بر حسب فاصله نشان می‌دهند که آیا خطاها «نزدیک» هستند. سه calibration metric (ECE، NLL و Brier) کیفیت احتمال‌های پیش‌بینی‌شده را می‌سنجند.




**شکل ۱۳:** چهار گروه metric و ورودی هر گروه.

**Quadratic Weighted Kappa (QWK).** توافق پیش‌بینی و برچسب، با جریمه‌ای متناسب با مجذور فاصلهٔ درجه‌ها. $O$ confusion matrix و $E$ ماتریس مورد انتظار تحت استقلال است:

$$\kappa_w = 1 - \frac{\sum_{i,j} w_{ij} O_{ij}}{\sum_{i,j} w_{ij} E_{ij}}, \qquad w_{ij} = \frac{(i-j)^2}{(K-1)^2} \tag{۸.۱}$$

**mean absolute error، F1 کلان، دقت و AUC.** $\mathrm{MAE} = \frac{1}{N}\sum_i |\hat{y}_i - y_i|$ فاصلهٔ متوسط پیش‌بینی از درجهٔ درست است. F1 metric F1 کلان میانگین F1 پنج درجه است و به درجه‌های few-shot وزن برابر می‌دهد. area under the curve (AUC) به روش one-vs-rest و با macro average محاسبه می‌شود؛ CLIP-DR در گزارش خود روش one-vs-one را به کار برده است و در مقایسه با اعداد آن مقاله باید به این تفاوت توجه کرد.

**local ordinal score (LOS).** سهم تصاویری که احتمال درجهٔ پیش‌بینی‌شده‌شان از هر دو درجهٔ همسایه بیشتر است، یعنی توزیع پیش‌بینی در آن نقطه قله دارد.

**ordinal decay consistency (ODC).** برای هر سطر $i$ از confusion matrix که normalisation سطری شده $(P_{ij})$، با حرکت از قطر به سمت دو لبه، مجموع افزایش‌های error mass شمرده می‌شود:

$$v_i = \sum_{j>i} \max\big(0,\ P_{i,j+1} - P_{i,j}\big) + \sum_{j<i} \max\big(0,\ P_{i,j-1} - P_{i,j}\big), \qquad \mathrm{ODC} = 1 - \frac{1}{|\mathcal{I}|}\sum_{i\in\mathcal{I}} v_i \tag{۹.۱}$$

مجموعهٔ $\mathcal{I}$ سطرهایی است که نمونه دارند. در صورت کامل $(\mathrm{ODC}_{\mathrm{full}})$، گام از خود قطر هم شمرده می‌شود و در صورت خارج‌قطری $(\mathrm{ODC}_{\mathrm{offdiag}})$ شمارش از یک گام بعد از قطر آغاز می‌شود. مقدار ۱ یعنی در هر سطر error mass با دور شدن از قطر هرگز افزایش نمی‌یابد. سهم سطرهایی که هیچ نقض ندارند هم گزارش می‌شود.

**error mass بر حسب فاصله.** مقدار $m_\Delta$ میانگین سطری جرم پیش‌بینی در فاصلهٔ $|\hat{y} - y| = \Delta$ است، برای $\Delta = 0, \ldots, 4$. مدل ترتیبی خوب بیشترین جرم را در $\Delta = 0$ و جرمی نزولی در فاصله‌های بعدی دارد.

**metricهای calibration.** expected calibration error (ECE) با ۱۵ بازهٔ هم‌عرض اطمینان محاسبه می‌شود. negative log-likelihood (NLL) و Brier score هر دو proper scoring rules هستند و کل توزیع احتمال را می‌سنجند:

$$\mathrm{ECE} = \sum_{m=1}^{15} \frac{|B_m|}{N} \big|\mathrm{acc}(B_m) - \mathrm{conf}(B_m)\big|, \qquad \mathrm{NLL} = -\frac{1}{N}\sum_{i} \log p_{i,y_i}, \qquad \mathrm{Brier} = \frac{1}{N}\sum_{i}\sum_{k} \big(p_{ik} - \mathbb{1}[y_i = k]\big)^2 \tag{۱۰.۱}$$

## ۸.۱ baselineها و ablationها

همهٔ baselineها با کد اصلی نویسندگانشان بررسی شده‌اند. برای هر کدام دو نسخه وجود دارد: نسخهٔ «matched» که فقط روش را از مقاله می‌گیرد و بقیهٔ شرایط (پشتوانهٔ RN50، بودجهٔ آموزش، preprocessing و داده) را با مدل ما یکسان نگه می‌دارد، و نسخهٔ «official» که دستور آموزش خود نویسندگان را اجرا می‌کند.

**جدول ۶:** baselineها در شاخهٔ master

| مدل | prompt learner | loss | image encoder و آموزش |
|---|---|---|---|
| OrdinalCLIP matched | ۱۳ context token آغازشده از جملهٔ متنی، ۳ پایهٔ interpolation، نقطهٔ پایان جمله | CE + KL | frozen؛ تنظیمات ما |
| OrdinalCLIP official | همان | CE + KL | full fine-tuning؛ RAdam، weight decay $5 \times 10^{-4}$، ۱۰۰ epoch، ImageNet preprocessing |
| matched CLIP-DR | ۱۰ context token تصادفی، ۵ rank token آزاد، نقطهٔ پایان جمله | CE + KL + loss رتبه؛ بدون SMS | LoRA؛ تنظیمات ما |
| official CLIP-DR | همان | همان | full fine-tuning؛ RAdam، بدون weight decay، ۳۱ epoch، ۶۴ batch |
| L2RCLIP (پیاده‌سازی ما) | RankFormer روی rank tokenها | CE + distance-weighted pairwise loss | LoRA؛ تنظیمات ما؛ بدون SMS و loss رتبه |

**KL loss در OrdinalCLIP.** برای هر درجهٔ $k$ که در batch حضور دارد، توزیع similarity آن درجه روی تصاویر batch به توزیعی تقریباً یکنواخت روی تصاویرِ همان درجه نزدیک می‌شود:

$$\mathcal{L}_{\mathrm{KL}} = \frac{1}{|\mathcal{K}_B|} \sum_{k \in \mathcal{K}_B} \mathrm{KL}\Big( \mathrm{softmax}_b\big(10\,\mathbb{1}[y_b = k]\big) \,\Big\|\, \mathrm{softmax}_b\big(s_{bk}\big) \Big) \tag{۱۱.۱}$$

**RankFormer block.** در پیاده‌سازی ما بر اساس مقالهٔ L2RCLIP، rank tokenها پیش از ورود به text encoder از یک attention block می‌گذرند: $R' = (1-\alpha)R + \alpha\,\mathrm{FFN}(\mathrm{MSA}(\mathrm{LN}(R)))$ با $\alpha = 0.5$، multi-head attention با ۴ سر

و feed-forward network $512 \to 2048 \to 512$ که لایهٔ خروجی‌اش با صفر آغاز می‌شود. مقدار $\alpha$ در مقاله گزارش نشده و انتخاب ماست.

**distance-weighted pairwise loss.** این loss از ایدهٔ L2RCLIP الهام گرفته اما همان loss مقاله نیست:

$$\mathcal{L}_{\text{pair}} = \frac{1}{B} \sum_{b} \sum_{j \neq y_b} |y_b - j| \cdot \big( -\log \sigma(s_{b,y_b} - s_{bj}) \big) \tag{۱۲.۱}$$

هرچه درجهٔ اشتباه دورتر باشد، نزدیک بودن تصویر به آن بیشتر جریمه می‌شود.

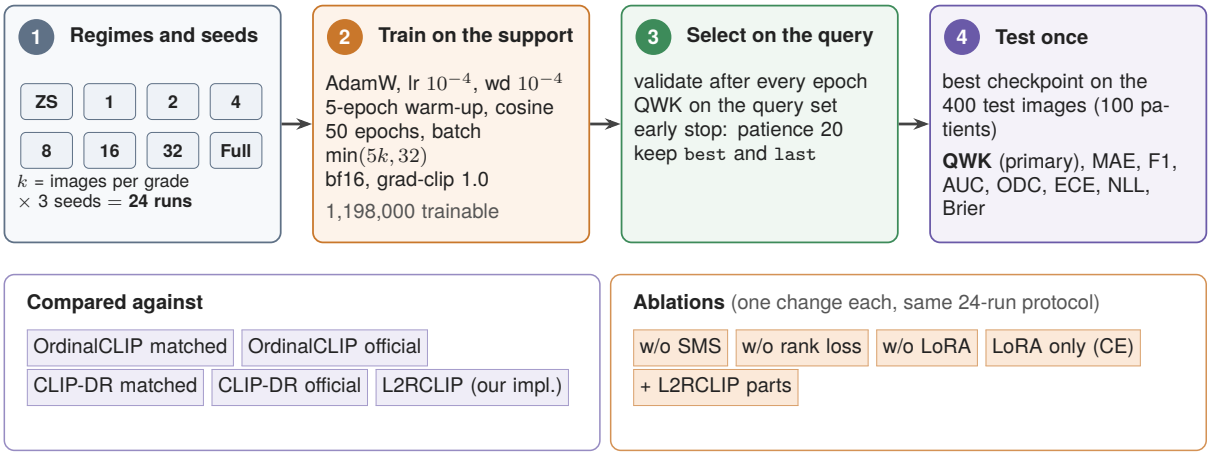
**جدول ۷:** ablationها مدل پایه (هر کدام فقط در یک جزء با مدل کامل تفاوت دارد)

| آزمایش | تغییر | پرسشی که پاسخ می‌دهد |
|---|---|---|
| بدون SMS | SMS خاموش | آیا هموارسازی آماری در آموزش کمک می‌کند؟ |
| بدون loss رتبه | $\lambda_{\text{rank}} = 0$ | سهم unimodal constraint |
| بدون LoRA | image encoder کاملاً frozen | نیاز به تطبیق image branch |
| فقط LoRA | بدون SMS و loss رتبه؛ فقط CE | عملکرد بدون هیچ جزء ترتیبی در loss |
| مدل ما + اجزای L2RCLIP | RankFormer و pairwise loss افزوده | آیا اجزای L2RCLIP چیزی اضافه می‌کنند؟ |

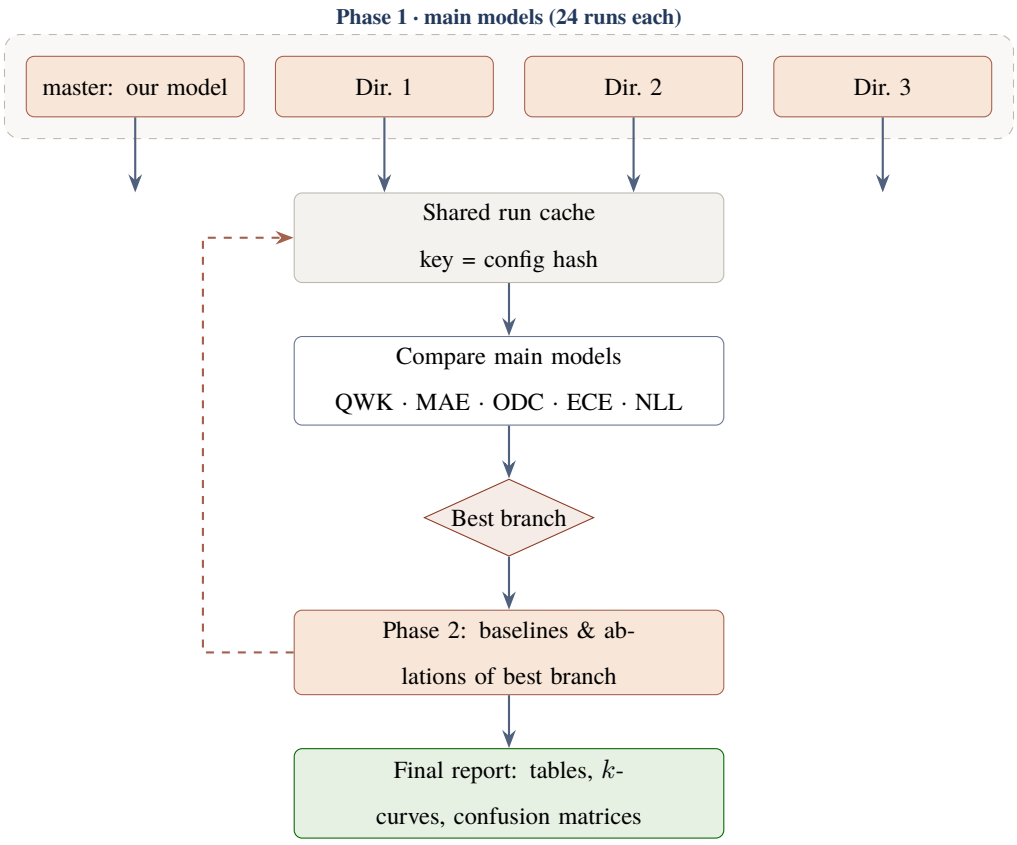
## ۹.۱ گردش کار آزمایش‌ها

آزمایش‌ها در دو مرحله اجرا می‌شوند. در مرحلهٔ ۱ فقط مدل اصلی هر شاخه در همهٔ مقدارهای $k$ و سه seed آموزش داده می‌شود (۸ regime × ۳ seed = ۲۴ اجرا برای هر مدل). سپس مدل‌های اصلی چهار شاخه کنار هم مقایسه می‌شوند. مرحلهٔ ۲، یعنی همهٔ baselineها و ablationها، فقط برای شاخه‌ای که در مرحلهٔ ۱ بهترین بوده و در پایان برای گزارش نهایی اجرا می‌شود.

همهٔ اجراها در یک shared cache ذخیره می‌شوند که کلید آن چکیدهٔ configuration کامل اجراست، نه نام آن. اگر دو notebook یک configuration یکسان را بخواهند، مثلاً «مدل ما» در master notebook و «مدل master» در notebook جهت ۳، فقط یک بار آموزش انجام می‌شود. مکان داده، تعداد کارگرهای بارگذار، $k$ و seed در کلید وارد نمی‌شوند؛ دو مورد آخر نام زیرپوشهٔ اجرا را تعیین می‌کنند. یکسان بودن کلیدها در هر چهار شاخه بررسی و تأیید شده است.




**شکل ۱۴:** protocol آزمایش‌های مدل پایه: regimeها و تکرارها، بهینه‌سازی، انتخاب مدل، اندازهٔ مدل، baselineها و ablationها.



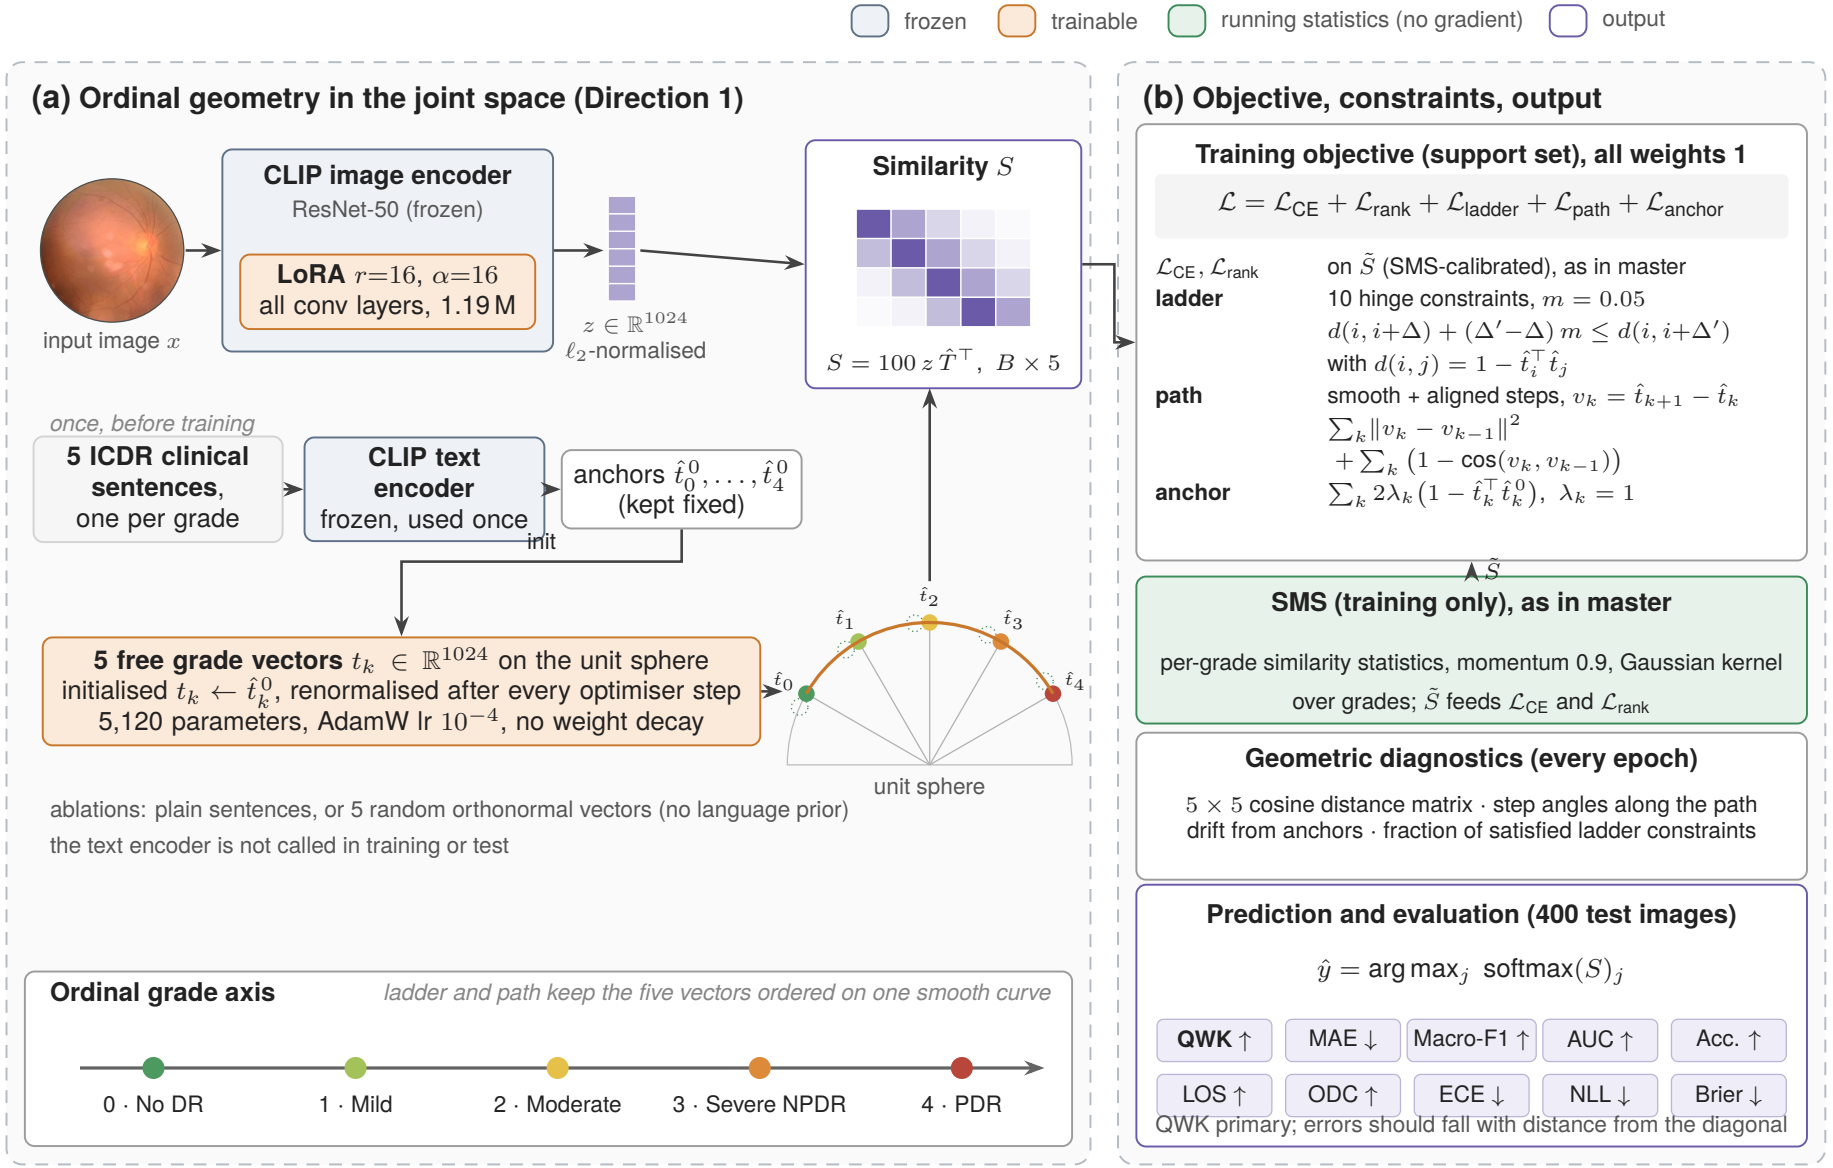

**شکل ۱۵:** گردش کار دو مرحله‌ای. اجرای تکراری یک configuration در هیچ notebookای دوباره آموزش داده نمی‌شود.

# ۲ جهت ۱: هندسهٔ ترتیبی مستقیم

**شاخه:** `direction1-ordinal-geometry`

پنج grade vector مستقیماً در فضای مشترک تصویر و متن آموخته می‌شوند و ترتیب، با سه constraint هندسی ladder، path و anchor، روی خود همین بردارها اعمال می‌شود. text encoder فقط یک بار برای initialisation به کار می‌رود.

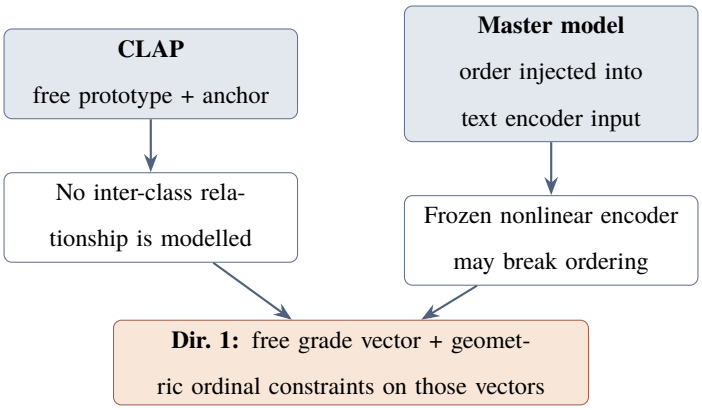
شکل ۱۶ گردش کار کامل جهت ۱ را نشان می‌دهد. داده و تقسیم آن همان مدل پایه است و تفاوت در blockهای مدل (الف) و loss function (ب) است؛ protocol آزمایش‌ها در شکل ۲۲ آمده است.




**شکل ۱۶:** گردش کار کامل جهت ۱: بردارهای آزاد درجه که یک بار از جمله‌های بالینی مقداردهی می‌شوند، constraintهای ladder، path و anchor روی همان بردارها و geometric diagnostics هر epoch.

## ۱.۲ انگیزه و شکاف پژوهشی

در مدل پایه، ترتیب از راه توکن‌های ورودی text encoder وارد می‌شود. rank tokenها شاید به هم نزدیک باشند، اما text encoder یک تابع غیرخطی و frozen است و هیچ تضمینی نیست که prototypeها خروجی، یعنی همان بردارهایی که similarity با آن‌ها سنجیده می‌شود، ترتیب را حفظ کنند. از سوی دیگر روش‌های جدید few-shot مانند CLAP [۵] prototypeها را مستقیماً در فضای مشترک می‌آموزند و با یک anchor به متن اولیه نزدیک نگه می‌دارند؛ اما این روش‌ها هیچ رابطه‌ای میان کلاس‌ها در نظر نمی‌گیرند. جهت ۱ این دو را ترکیب می‌کند: پنج grade vector مستقیماً در فضای مشترک آموخته می‌شوند و ترتیب، با geometric constraints، روی خود همین بردارها اعمال می‌شود.



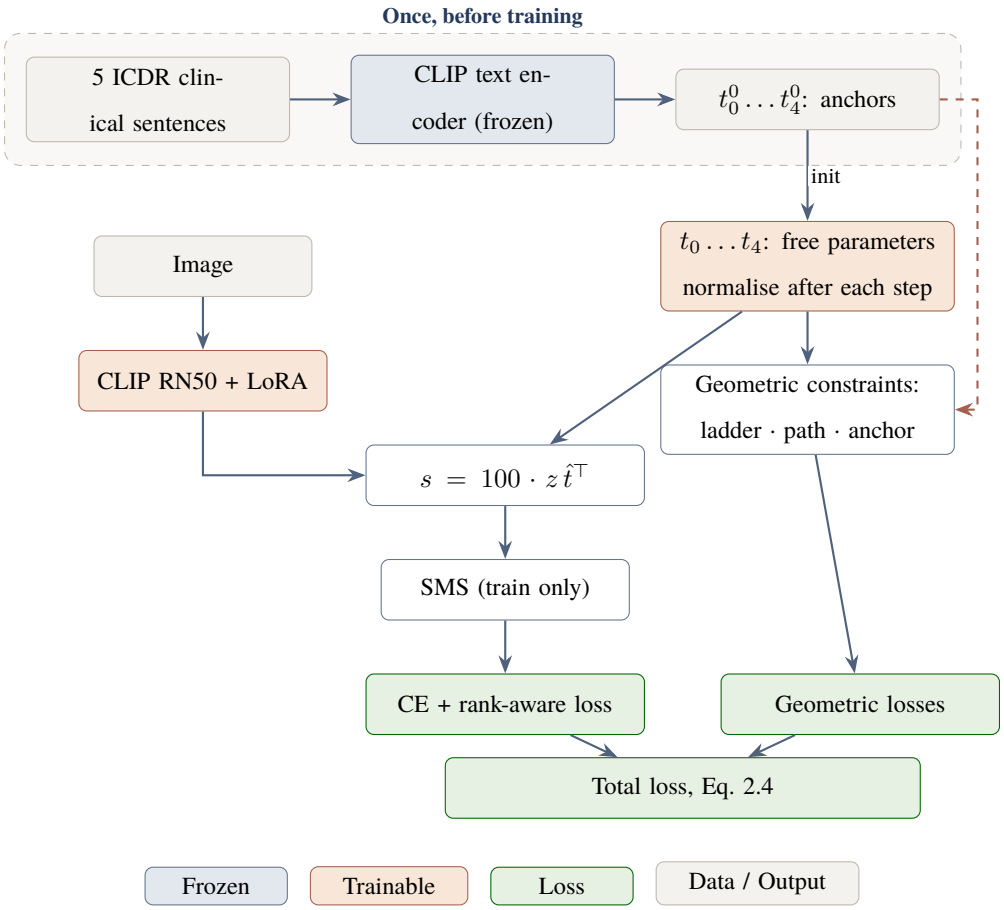

**شکل ۱۷:** شکاف پژوهشی جهت ۱: ترکیب prototype آزاد (مانند CLAP) با constraint ترتیبی مستقیم.

## ۲.۲ تفاوت با مدل پایه

**جدول ۸:** آنچه در جهت ۱ تغییر می‌کند و آنچه ثابت می‌ماند

| جزء | مدل پایه | جهت ۱ |
|---|---|---|
| نمایش درجه‌ها | frozen text encoder از learnable prompt | پنج بردار آزاد ۱۰۲۴ـ بعدی روی unit sphere |
| text encoder در آموزش | در هر گام فراخوانی می‌شود | فقط یک بار برای initialisation |
| constraint ترتیبی روی نمایش | interpolation توکن‌ها | distance ladder، smooth path، anchor به متن |
| image branch، داده، SMS، loss رتبه، metricها، آموزش | | یکسان (بخش‌های ۲.۱ تا ۷.۱) |

## ۳.۲ معماری



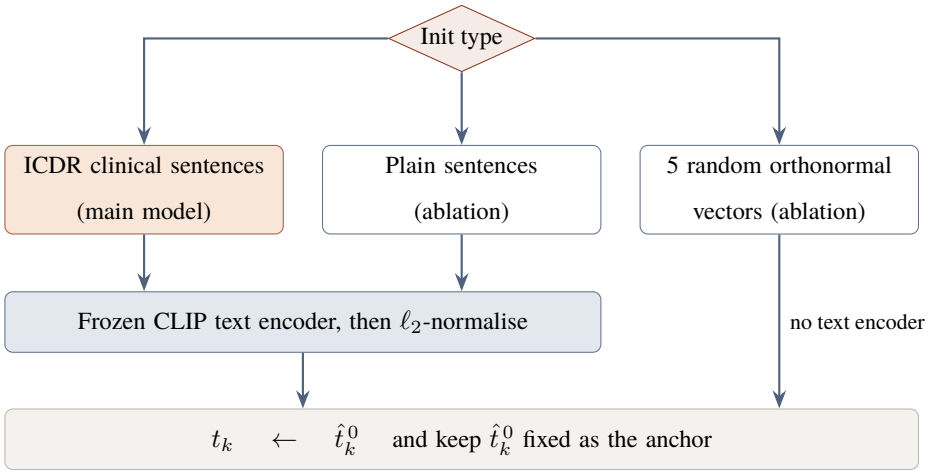

**شکل ۱۸:** معماری جهت ۱. text encoder فقط در initialisation به کار می‌رود و در آموزش و آزمون حذف می‌شود.

## ۴.۲ grade vector initialisationها

هر grade vector با کدگذاری یک جملهٔ بالینی مطابق مقیاس ICDR [۱۱] توسط frozen text encoder آغاز می‌شود و نسخهٔ نرمال‌شدهٔ همین بردار به‌عنوان anchor $\hat{t}_k^0$ نگه داشته می‌شود. در ablationها دو مقداردهی دیگر هم بررسی می‌شود: جمله‌های ساده (برای نمونه "A fundus photograph with mild non-proliferative diabetic retinopathy.") و پنج بردار متعامد تصادفی بدون هیچ دانش زبانی.

**جدول ۹:** جمله‌های بالینی initialisation (به زبان اصلی، همان‌گونه که به encoder داده می‌شوند)

| درجه | جمله |
|---|---|
| ۰ | A fundus photograph showing no diabetic retinopathy, with normal retinal vasculature and no microaneurysms or hemorrhages. |
| ۱ | A fundus photograph showing mild non-proliferative diabetic retinopathy, characterized by the presence of microaneurysms only. |
| ۲ | A fundus photograph showing moderate non-proliferative diabetic retinopathy, with multiple microaneurysms, dot and blot hemorrhages, hard exudates, or cotton wool spots, less than severe. |
| ۳ | A fundus photograph showing severe non-proliferative diabetic retinopathy, with extensive intraretinal hemorrhages in four quadrants, venous beading, or intraretinal microvascular abnormalities. |
| ۴ | A fundus photograph showing proliferative diabetic retinopathy, characterized by neovascularization on the optic disc or elsewhere, vitreous hemorrhage, or preretinal hemorrhage. |




**شکل ۱۹:** سه گزینهٔ مقداردهی grade vectorها.

## ۵.۲ ordinal geometric constraints

همهٔ constraintها روی بردارهای نرمال‌شدهٔ $\hat{t}_k$ و با cosine distance $d(i,j) = 1 - \hat{t}_i^\top \hat{t}_j$ تعریف می‌شوند.

### ۱.۵.۲ distance ladder

از دید هر درجه، درجهٔ نزدیک‌تر باید از درجهٔ دورتر نزدیک‌تر باشد و این تفاوت با فاصلهٔ درجه‌ها marginای متناسب داشته باشد. برای پنج درجه، ۱۰ constraint از این نوع وجود دارد:

$$\mathcal{L}_{\text{ladder}} = \sum_{i} \sum_{1 \le \Delta < \Delta' \le K-1-i} \max\Big(0,\ d(i, i{+}\Delta) - d(i, i{+}\Delta') + (\Delta' - \Delta)\, m\Big), \qquad m = 0.05 \quad (۱.۲)$$

### ۲.۵.۲ smooth path

پنج بردار باید روی یک خم یک‌بعدی و هموار روی sphere قرار بگیرند تا ترتیب درجه‌ها در هندسه دیده شود. با گام‌های $v_k = \hat{t}_{k+1} - \hat{t}_k$، دو جزء تعریف می‌شود: هموار بودن (مشتق دوم کوچک) و هم‌جهت بودن گام‌های پیاپی:

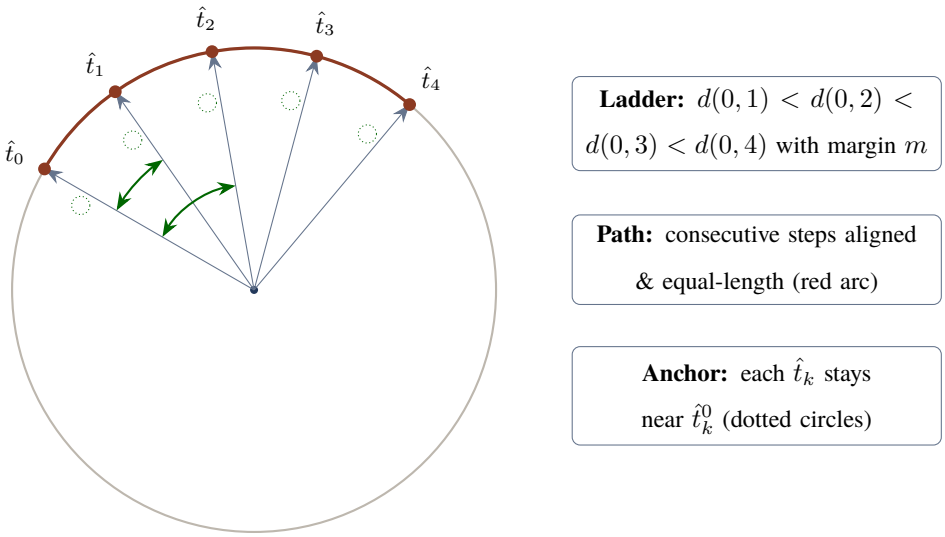
$$\mathcal{L}_{\text{smooth}} = \sum_{k=1}^{K-2} \|v_k - v_{k-1}\|^2, \qquad \mathcal{L}_{\text{align}} = \sum_{k=1}^{K-2} \big(1 - \cos(v_k, v_{k-1})\big), \tag{۲.۲}$$
$$\mathcal{L}_{\text{path}} = \mathcal{L}_{\text{smooth}} + \mathcal{L}_{\text{align}}$$

### ۳.۵.۲ anchor

در 1-shot regime یا 2-shot، بردارهای آزاد به‌آسانی overfitting می‌کنند و دانش زبانی اولیه را از دست می‌دهند. anchor هر بردار را به نقطهٔ آغازش نزدیک نگه می‌دارد. روی unit sphere، مجذور Euclidean distance برابر $2(1 - \cos)$ است:

$$\mathcal{L}_{\text{anchor}} = \sum_{k} \lambda_k \|\hat{t}_k - \hat{t}_k^0\|^2 = \sum_{k} 2\lambda_k \big(1 - \hat{t}_k^\top \hat{t}_k^0\big) \tag{۳.۲}$$

در مدل اصلی همهٔ $\lambda_k$ برابر ۱ هستند. دو وزن‌دهی دیگر در ablation بررسی می‌شوند: وزن متناسب با معکوس ریشهٔ فراوانی هر درجه در دادهٔ آموزش (با میانگین ۱)، و وزن CLAP که برابر میانگین احتمال zero-shot درجهٔ درست روی تصاویر support همان درجه است.




**شکل ۲۰:** سه constraint هندسی روی gradeهای vector. ladder ترتیب فاصله‌ها، مسیر شکل کلی و anchor پیوند با دانش زبانی را حفظ می‌کند.

## ۶.۲ loss function کل

$$\mathcal{L} = \mathcal{L}_{\text{CE}}(\tilde{s}, y) + \mathcal{L}_{\text{rank}}(\tilde{s}, y) + \mathcal{L}_{\text{ladder}} + \mathcal{L}_{\text{path}} + \mathcal{L}_{\text{anchor}} \tag{۴.۲}$$

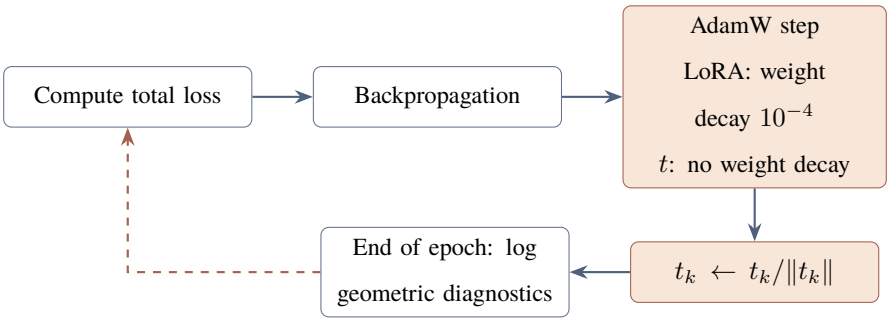
همهٔ وزن‌ها برابر ۱ هستند و $\tilde{s}$ همان calibrated similarity با SMS است (رابطهٔ ۵.۱). distance-weighted pairwise loss (رابطهٔ ۱۲.۱) در مدل اصلی جهت ۱ وجود ندارد و فقط در ablation «+ pairwise loss» افزوده می‌شود.

**جدول ۱۰:** اجزای loss function جهت ۱

| جزء | روی چه چیزی | وزن | نقش |
|---|---|---|---|
| cross-entropy | $\tilde{s}$ | ۱ | طبقه‌بندی درست |
| ranking-aware loss | $\tilde{s}$ | ۱ | شکل similarity unimodal هر تصویر |
| (۱.۲) ladder | $\hat{t}_k$ | ۱ | ترتیب فاصله‌ها میان درجه‌ها |
| مسیر (۲.۲) | $\hat{t}_k$ | ۱ | قرار گرفتن درجه‌ها روی یک خم هموار |
| (۳.۲) anchor | $\hat{t}_k, \hat{t}_k^0$ | ۱ | جلوگیری از overfitting و حفظ دانش زبانی |

## ۷.۲ بهینه‌سازی

grade vectorها با AdamW و همان learning rate $10^{-4}$ اما بدون weight decay آموخته می‌شوند، چون weight decay روی parameterی که دوباره به sphere تصویر می‌شود فقط اندازهٔ گام مؤثر را تغییر می‌دهد. پس از هر گام optimizer، هر بردار دوباره به طول واحد نرمال می‌شود. بقیهٔ تنظیمات همان جدول ۵ است. parameterهای trainable ۱,۱۸۸,۲۷۲ (LoRA) به‌اضافهٔ $5 \times 1024 =$ ۵,۱۲۰ (grade vectorها)، در مجموع ۱,۱۹۳,۳۹۲ هستند.




**شکل ۲۱:** یک گام بهینه‌سازی در جهت ۱. normalisation پس از هر گام بردارها را روی sphere نگه می‌دارد.

## ۸.۲ داده، ارزیابی و geometric diagnostics

داده، few-shot protocol، preprocessing و همهٔ metricهای بخش ۷.۱ بدون تغییر به کار می‌روند: ۲۴ اجرا برای مدل اصلی ($k \in \{-1, 0, 1, 2, 4, 8, 16, 32\}$ با ۳ seed)، آزمون روی ۴۰۰ تصویر و QWK به‌عنوان metric اصلی. در حالت zero-shot، مدل همان CLIP zero-shot classifier با جمله‌های بالینی است. افزون بر metricها، در پایان هر epoch چهار تشخیص هندسی ذخیره می‌شود:

۱. ماتریس cosine distance $5 \times 5$ بین درجه‌ها؛

۲. زاویهٔ چرخش میان گام‌های پیاپی path؛

۳. فاصلهٔ هر بردار از anchorاش؛

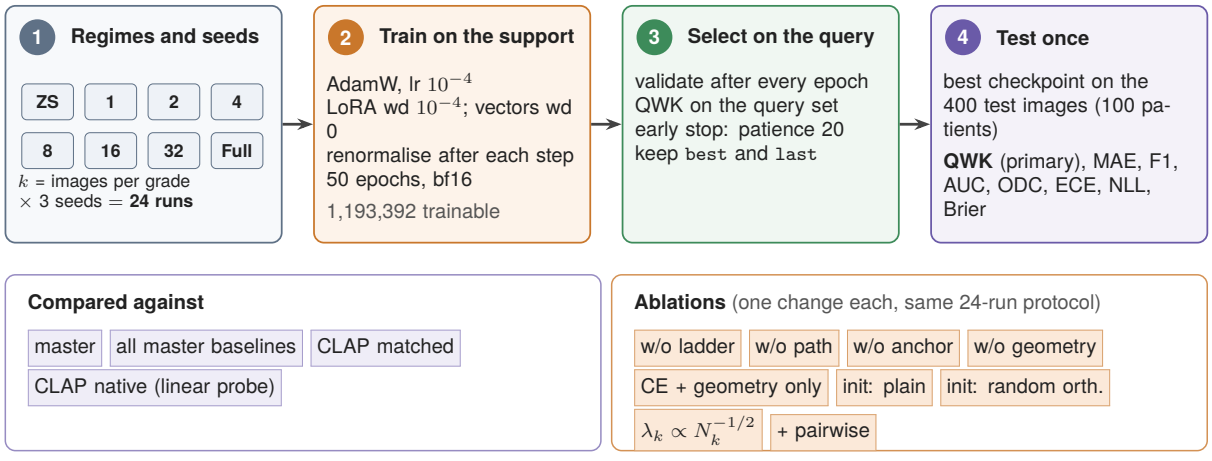
۴. سهم constraintهای ladder برقرار (از ۱۰ constraint).

## ۹.۲ baselineها و ablationها

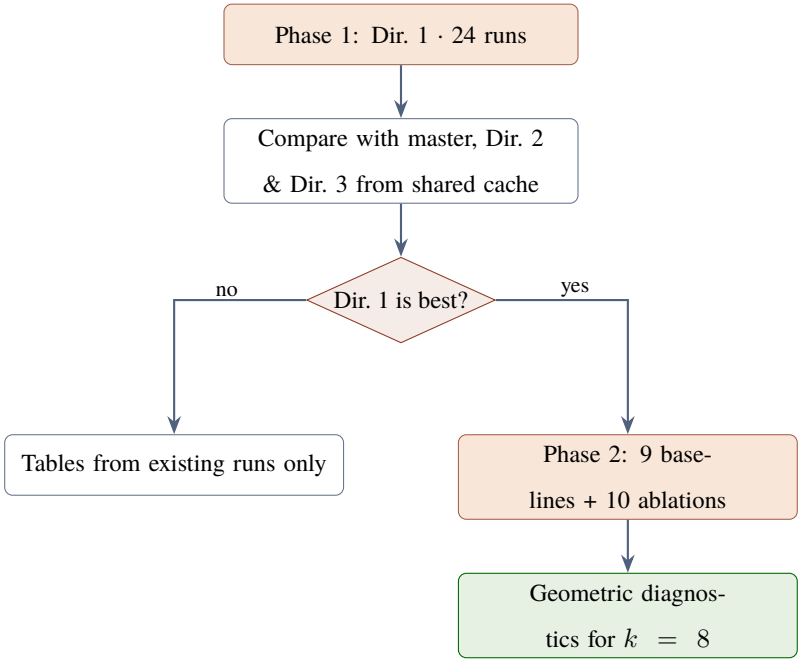
مقایسه شامل مدل master، همهٔ مدل‌های جدول ۶ و دو نسخه از CLAP است. matched CLAP با جمله‌های ساده آغاز می‌شود، وزن CLAP anchor را به کار می‌برد، فقط CE loss و anchor دارد و LoRA تصویر را حفظ می‌کند. official CLAP یک linear probe روی ویژگی‌های frozen است: بدون LoRA، با SGD و نرخ ۰/۱ به مدت ۳۰۰ epoch و بدون early stopping.

**جدول ۱۱:** ablationها جهت ۱

| آزمایش | تغییر نسبت به مدل اصلی |
|---|---|
| بدون ladder / بدون path / بدون anchor | وزن همان constraint صفر |
| بدون geometric constraints | هر سه constraint صفر |
| فقط CE و هندسه | بدون loss رتبه و SMS |
| مقداردهی با جمله‌های ساده | جمله‌های کوتاه به‌جای جمله‌های بالینی |
| مقداردهی متعامد تصادفی | بدون هیچ دانش زبانی |
| anchor با معکوس ریشهٔ فراوانی | $\lambda_k \propto 1/\sqrt{N_k}$ |
| pairwise loss + | افزودن distance-weighted pairwise loss |




**شکل ۲۲:** protocol آزمایش‌های جهت ۱.



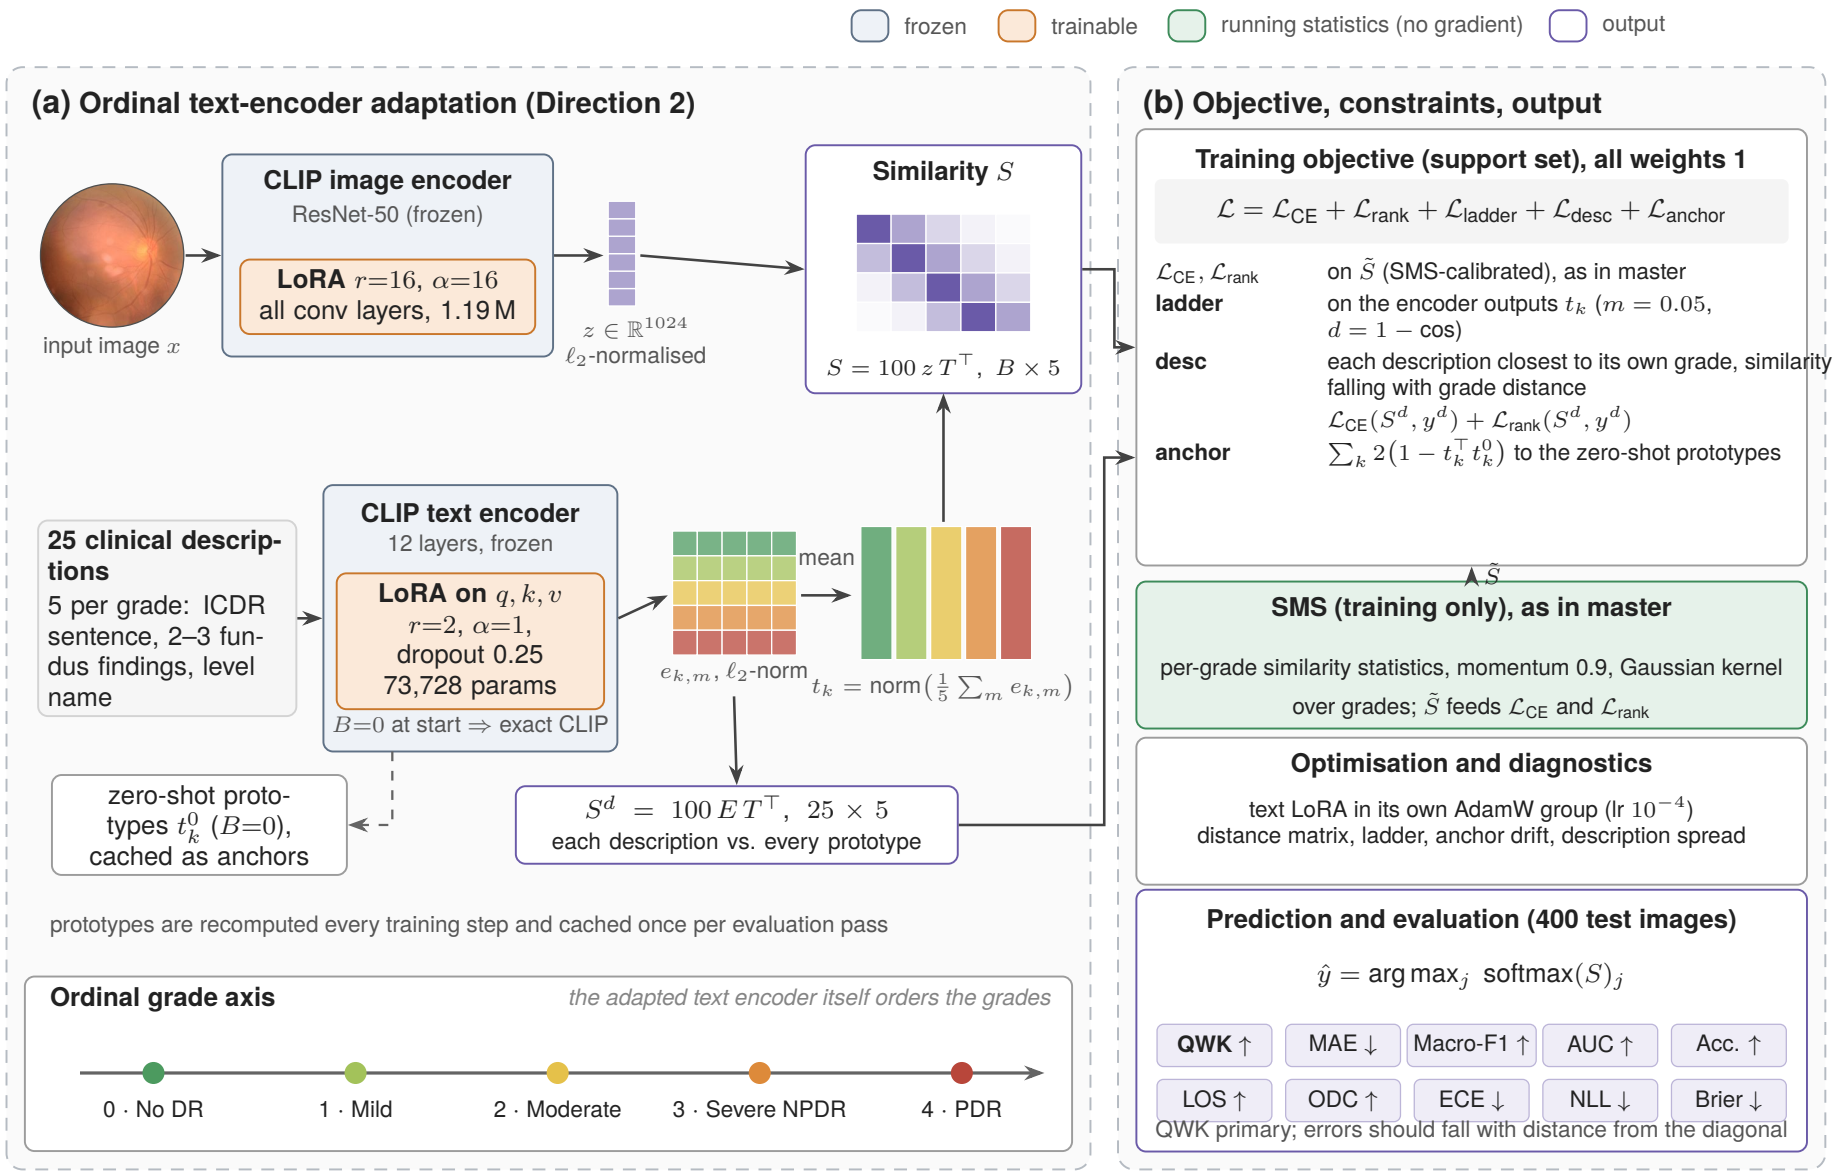

**شکل ۲۳:** گردش کار آزمایش‌های جهت ۱.

# ۳ جهت ۲: low-rank adaptation of the text encoder

**شاخه:** `direction2-ordinal-text-lora`

درجه‌ها با ۲۵ توصیف بالینی واقعی بیان می‌شوند و خود text encoder با LoRA برای درجه‌بندی DR تنظیم می‌شود. ترتیب روی خروجی text encoder اعمال می‌شود، پس encoder تطبیق‌یافته، و نه فقط پنج بردار، ترتیب درجه‌ها را می‌آموزد.

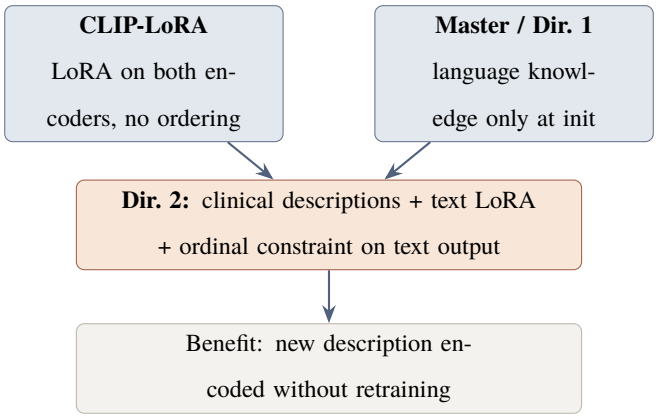
شکل ۲۴ گردش کار کامل جهت ۲ را نشان می‌دهد: ۲۵ توصیف بالینی از text encoder تطبیق‌یافته با LoRA می‌گذرند و constraintهای ترتیبی روی خروجی آن اعمال می‌شوند. protocol آزمایش‌ها در شکل ۳۰ آمده است.




**شکل ۲۴:** گردش کار کامل جهت ۲: توصیف‌های بالینی، LoRA روی $q$، $k$ و $v$ text encoder، prototypeها میانگین، similarity matrix توصیف‌ها $S^d$ و loss function با constraintهای ladder، description و ordering و anchor.

## ۱.۳ انگیزه و شکاف پژوهشی

مدل پایه prompt را می‌آموزد و جهت ۱ grade vectorها را؛ در هر دو، دانش زبانی فقط در نقطهٔ شروع حضور دارد. جهت ۲ برعکس عمل می‌کند: درجه‌ها با زبان بالینی واقعی توصیف می‌شوند و این بار خود text encoder، با low-rank adaptation، برای درجه‌بندی DR تنظیم می‌شود. ایده از CLIP-LoRA [۶] گرفته شده که LoRA را روی هر دو encoder اعمال می‌کند، اما آن روش برای کلاس‌های بدون ترتیب طراحی شده است. نوآوری جهت ۲ این است که ترتیب روی خروجی text encoder اعمال می‌شود. یک پیامد عملی هم دارد: توصیف تازه‌ای از یک درجه را می‌توان بدون آموزش دوباره کدگذاری کرد.



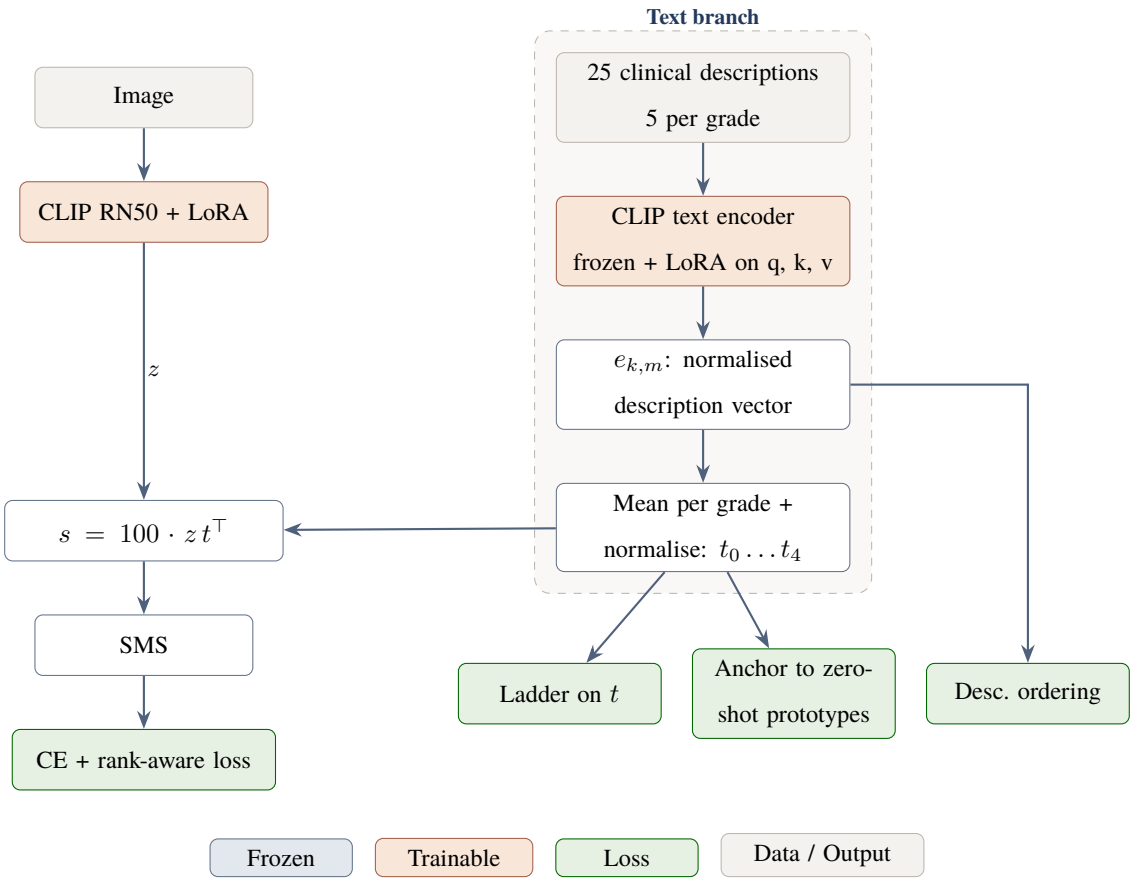

**شکل ۲۵:** شکاف پژوهشی جهت ۲.

## ۲.۳ تفاوت با مدل پایه

**جدول ۱۲:** آنچه در جهت ۲ تغییر می‌کند

| جزء | مدل پایه | جهت ۲ |
|---|---|---|
| ورودی text branch | توکن‌های learnable | ۲۵ توصیف بالینی ثابت (۵ برای هر درجه) |
| text encoder | frozen | LoRA + frozen روی q، k و v در هر ۱۲ لایه |
| prototype درجه | خروجی یک prompt | میانگین نرمال‌شدهٔ ۵ توصیف |
| constraint ترتیبی روی نمایش | interpolation توکن‌ها | ladder، description ordering، anchor |
| image branch، داده، SMS، loss رتبه، metricها، آموزش | | یکسان با بخش ۱ |

## ۳.۳ معماری



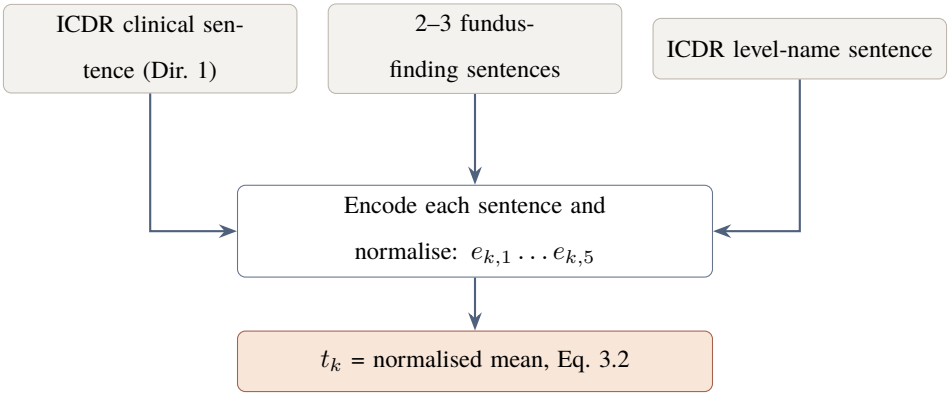

**شکل ۲۶:** معماری جهت ۲. LoRA متن و LoRA تصویر هم‌زمان آموخته می‌شوند.

## ۴.۳ توصیف‌های بالینی

برای هر درجه پنج توصیف به زبان انگلیسی نوشته شده است: جملهٔ بالینی جهت ۱، دو یا سه جمله دربارهٔ یافته‌های معمول فوندوس در آن درجه (میکروآنوریسم، خونریزی نقطه‌ای و لکه‌ای، اگزودای سخت، لکهٔ پنبه‌ای، تسبیحی شدن وریدها، ناهنجاری‌های ریزرگی درون شبکیه، نئوواسکولاریزاسیون) و یک جمله که سطح ICDR را نام می‌برد. همهٔ توصیف‌ها در محدودهٔ ۷۷ توکن CLIP جا می‌شوند. میانگین‌گیری چند توصیف (CuPL [۹]) وابستگی prototype به جمله‌بندی یک جملهٔ خاص را کم می‌کند.

**جدول ۱۳:** نمونهٔ توصیف‌های درجهٔ ۳ (شدید غیرتکثیری)

| # | توصیف |
|---|---|
| ۱ | A fundus photograph showing severe non-proliferative diabetic retinopathy, with extensive intraretinal hemorrhages in four quadrants, venous beading, or intraretinal microvascular abnormalities. |
| ۲ | A retina with many intraretinal hemorrhages in all four quadrants and definite venous beading. |
| ۳ | A color fundus image with intraretinal microvascular abnormalities and widespread hemorrhages but no new vessels. |
| ۴ | Severe diabetic retinopathy meeting the 4-2-1 rule, without neovascularization. |
| ۵ | Fundus photography graded as ICDR level 3, severe non-proliferative retinopathy. |




**شکل ۲۷:** ساختن prototype هر درجه از پنج توصیف.

## ۵.۳ low-rank adaptation of the text encoder

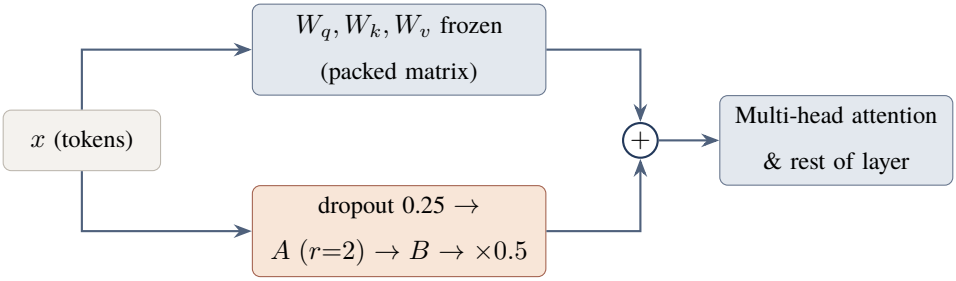
لایه‌های توجه CLIP text encoder، ماتریس‌های query، کلید و مقدار را در یک ماتریس بسته‌بندی‌شده نگه می‌دارند و ابزارهای رایج LoRA نمی‌توانند هر کدام را جداگانه هدف بگیرند. به همین دلیل، مطابق CLIP-LoRA، هر attention block با blockی جایگزین می‌شود که وزن‌های frozen را نگه می‌دارد و به‌روزرسانی کم‌رتبه را با dropout روی ورودی می‌افزاید:

$$h_\star = W_\star\, x + \frac{\alpha}{r}\, B_\star A_\star\, \mathrm{dropout}(x), \qquad \star \in \{q, k, v\} \tag{۱.۳}$$

تنظیمات پیش‌فرض CLIP-LoRA به کار می‌رود: $r = 2$، $\alpha = 1$ (ضریب ۰/۵) و dropout ۰/۲۵، روی هر ۱۲ لایه. ماتریس $B$ با صفر آغاز می‌شود و آزمون نشان داده است که در این حالت خروجی encoder دقیقاً با CLIP اصلی برابر است. تعداد parameterهای LoRA متن $12 \times 3 \times 2 \times 2 \times 512$ = ۷۳,۷۲۸ است.

$$e_{k,m} = \frac{g_\theta(s_{k,m})}{\|g_\theta(s_{k,m})\|}, \qquad t_k = \frac{\frac{1}{M}\sum_{m=1}^{M} e_{k,m}}{\left\|\frac{1}{M}\sum_{m} e_{k,m}\right\|}, \qquad M = 5 \tag{۲.۳}$$

در ارزیابی، prototypeها در طول یک دور ارزیابی تغییر نمی‌کنند و یک بار محاسبه می‌شوند. prototypeهای zero-shot ($B = 0$ با) به‌عنوان anchor $t_k^0$ نگه داشته می‌شوند.




**شکل ۲۸:** attention block بازنویسی‌شده با LoRA روی q، k و v (رابطهٔ ۱.۳).

## ۶.۳ constraintهای ترتیبی روی خروجی متن

**ladder روی prototypeها.** همان رابطهٔ ۱.۲ جهت ۱، این بار روی $t_k$ که خروجی encoder است.

**description ordering.** هر توصیف باید بیشترین similarity را با درجهٔ خودش داشته باشد و similarity آن با درجه‌های دیگر با فاصله کاهش یابد. $25 \times 5$ similarity matrix توصیف‌ها و prototypeها ساخته می‌شود و همان زوج image branch loss روی آن اعمال می‌شود:

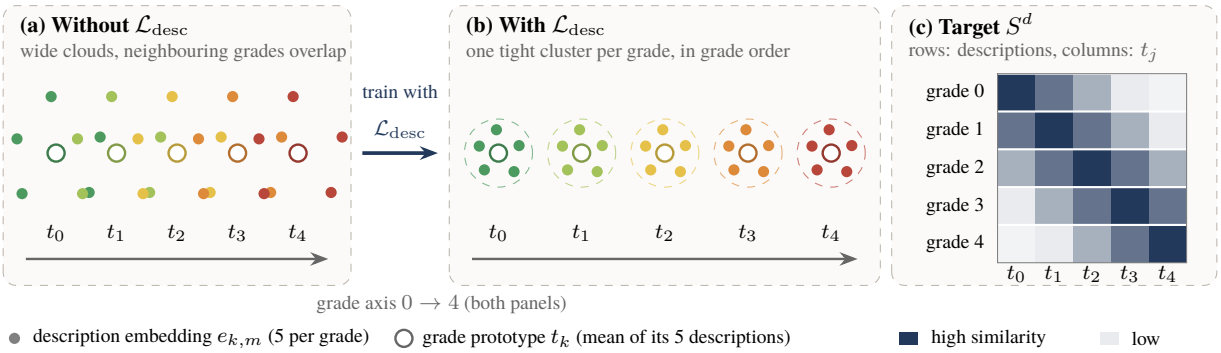
$$S^d_{(k,m),j} = 100 \cdot e_{k,m}^\top t_j, \qquad \mathcal{L}_{\text{desc}} = \mathcal{L}_{\text{CE}}(S^d, y^d) + \mathcal{L}_{\text{rank}}(S^d, y^d) \tag{۳.۳}$$

این constraint ابر توصیف‌های هر درجه را از درجه‌های دیگر جدا و در امتداد محور درجه مرتب نگه می‌دارد. اگر encoder برای کم کردن loss تصویر، توصیف‌های دو درجهٔ همسایه را روی هم بیندازد، این constraint جلوی آن را می‌گیرد.

**anchor.** رابطهٔ ۳.۲ با $t_k^0$ zero-shot، تا encoder در regime بسیار few-shot از دانش اولیه دور نشود.

$$\mathcal{L} = \mathcal{L}_{\text{CE}}(\tilde{s}, y) + \mathcal{L}_{\text{rank}}(\tilde{s}, y) + \mathcal{L}_{\text{ladder}} + \mathcal{L}_{\text{desc}} + \mathcal{L}_{\text{anchor}} \tag{۴.۳}$$

همهٔ وزن‌ها ۱ هستند. path constraint و pairwise loss در مدل اصلی خاموش‌اند.




**شکل ۲۹:** هدف description ordering (رابطهٔ ۳.۳). (الف) بدون این constraint، توصیف‌های درجه‌های همسایه روی هم می‌افتند. (ب) cross-entropy روی $S^d$ توصیف‌های هر درجه را دور prototype همان درجه جمع می‌کند و ranking-aware loss روی $S^d$ این خوشه‌ها را در امتداد محور درجه مرتب نگه می‌دارد. (ج) الگوی هدف ماتریس $S^d$: بیشترین similarity هر توصیف با درجهٔ خودش است و با فاصلهٔ درجه کاهش می‌یابد.

## ۷.۳ آموزش، داده و ارزیابی

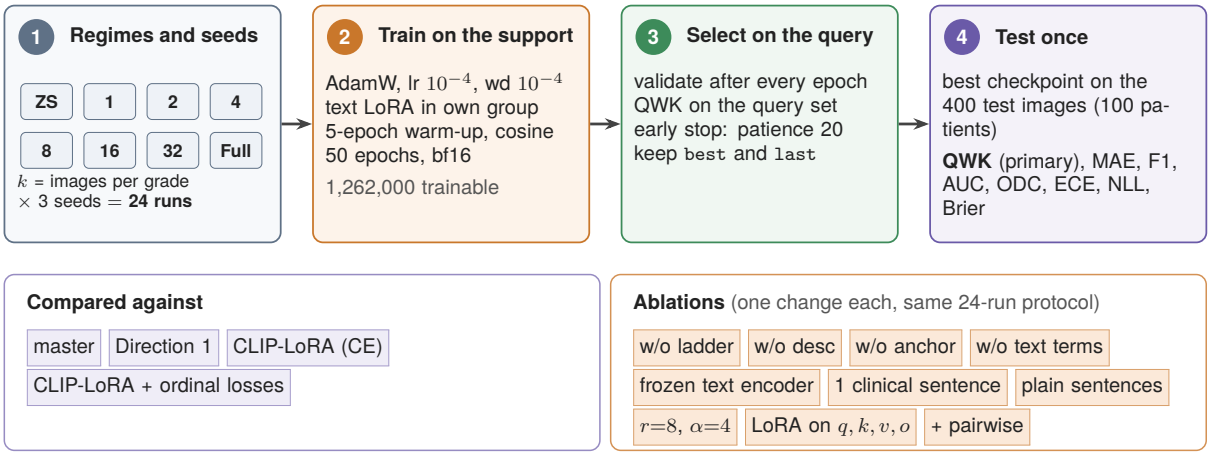
parameterهای LoRA متن در یک گروه جداگانهٔ optimizer با همان learning rate $10^{-4}$ و weight decay آموخته می‌شوند. بقیهٔ تنظیمات، داده، protocol ۲۴ اجرایی و metricها همان بخش ۱ است و کل parameterهای trainable ۱,۱۸۸,۲۷۲ + ۷۳,۷۲۸ = ۱,۲۶۲,۰۰۰ است. در حالت zero-shot، مدل همان CLIP zero-shot classifier با میانگین ۲۵ توصیف است. تشخیص‌های هر epoch علاوه بر موارد جهت ۱، پراکندگی توصیف‌های هر درجه گرد prototypeاش (میانگین $1 - \cos$) را هم ثبت می‌کند.

## ۸.۳ baselineها و ablationها

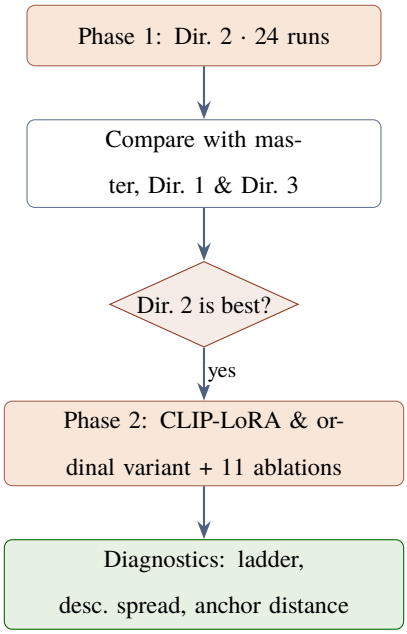
دو مقایسهٔ اختصاصی این جهت عبارت‌اند از CLIP-LoRA (LoRA روی هر دو encoder، prompt قالبی "a photo of a {grade}.") و فقط CE loss) و CLIP-LoRA با lossهای ترتیبی ما (CE، ranking-aware loss و SMS). مقایسهٔ دوم پاسخ می‌دهد که آیا constraintهای ترتیبی روی خروجی متن لازم‌اند یا lossهای سمت تصویر کافی است. مدل master، جهت ۱ و مدل‌های جدول ۶ هم در مقایسه حضور دارند.

**جدول ۱۴:** ablationها جهت ۲

| آزمایش | تغییر نسبت به مدل اصلی |
|---|---|
| بدون ladder / بدون description ordering / بدون anchor | وزن همان constraint صفر |
| بدون constraintهای متنی | هر سه constraint صفر |
| frozen text encoder | بدون LoRA متن؛ prototypeها ثابت و برابر میانگین zero-shot |
| یک جملهٔ بالینی | فقط جملهٔ اول هر درجه |
| جمله‌های ساده | یک جملهٔ کوتاه برای هر درجه |
| رتبهٔ ۸ | $r = 8,\ \alpha = 4$ |
| LoRA روی q، k، v و o | افزودن تصویر خروجی توجه |
| + pairwise loss | افزودن distance-weighted pairwise loss |




**شکل ۳۰:** protocol آزمایش‌های جهت ۲.



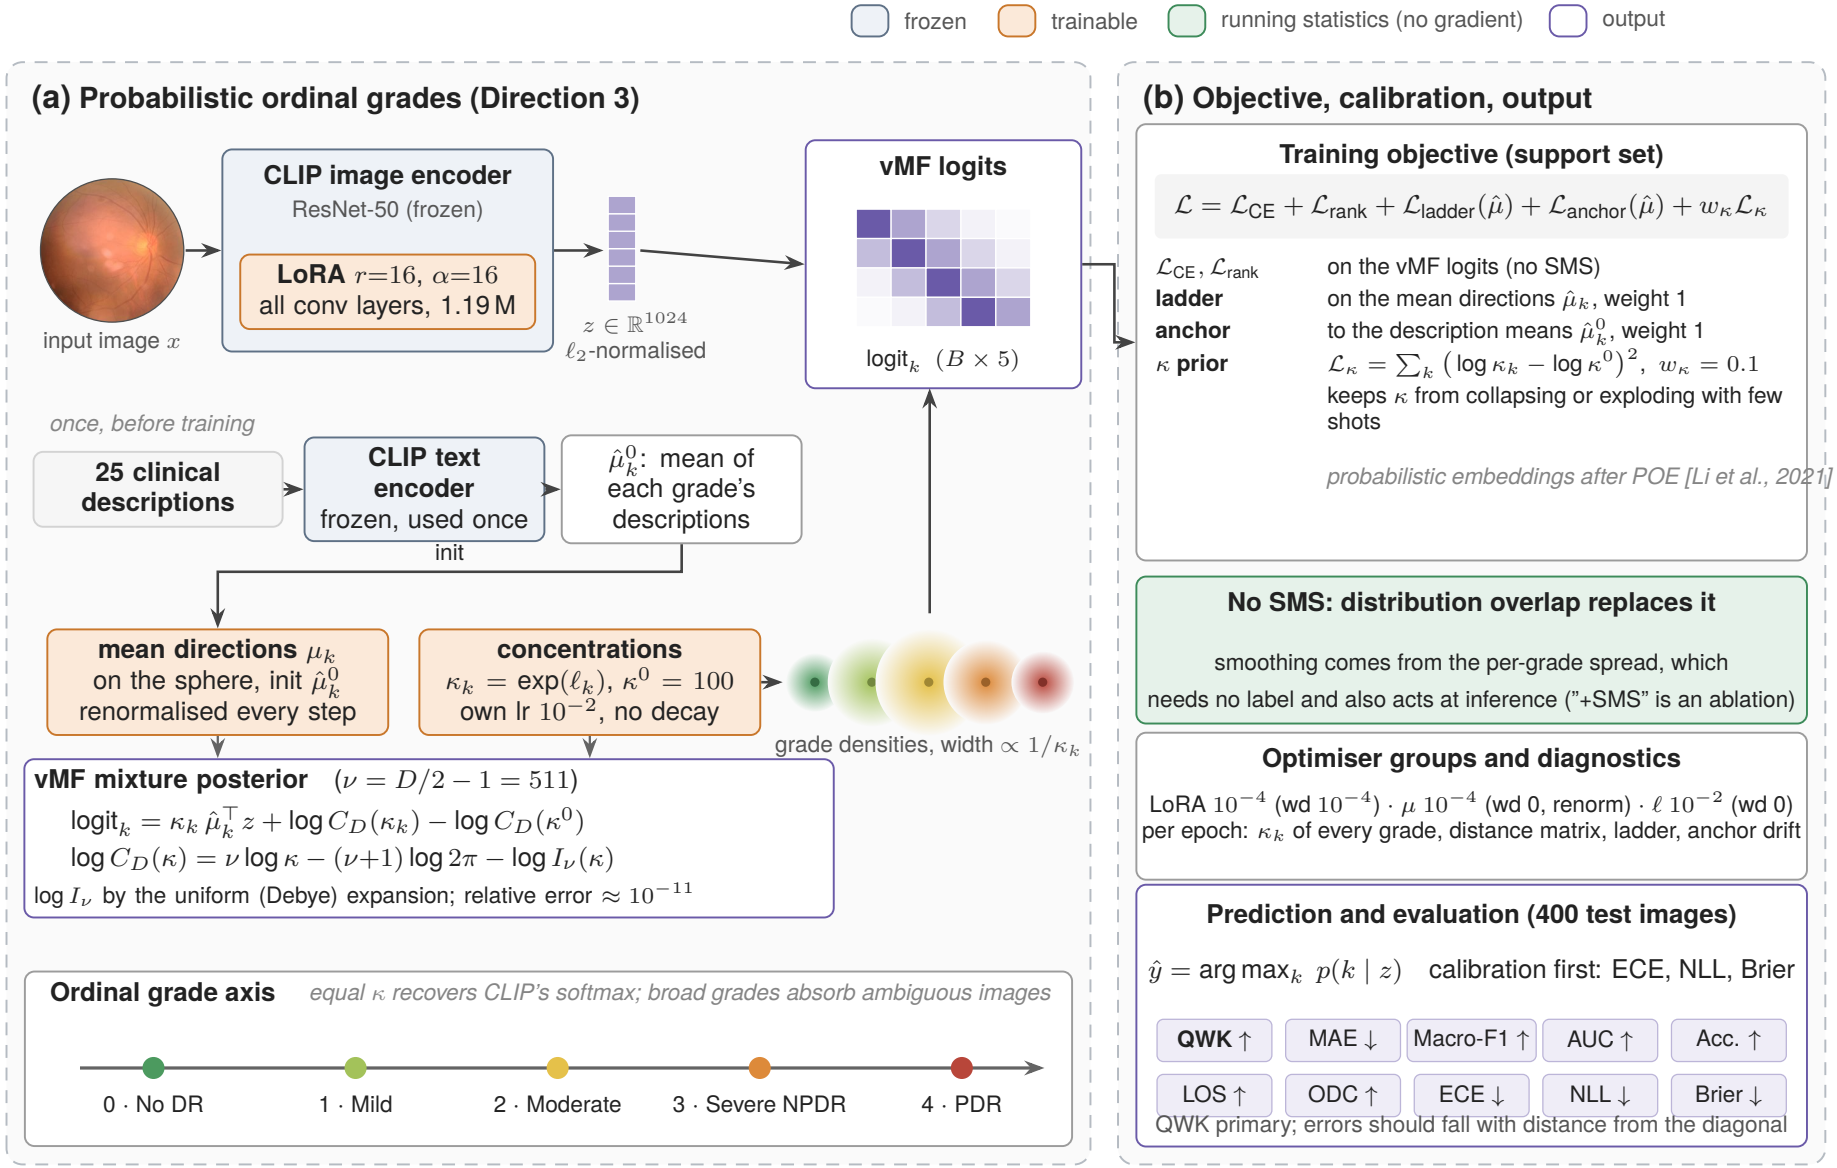

**شکل ۳۱:** گردش کار آزمایش‌های جهت ۲.

# ۴ جهت ۳: نمایش احتمالاتی درجه‌ها

**شاخه:** `direction3-probabilistic-ordinal`

هر درجه یک von Mises–Fisher distribution روی unit sphere است: یک mean direction که درجه را مکان‌یابی می‌کند و یک trainable concentration که ابهام آن درجه را نشان می‌دهد. mixture posterior این توزیع‌ها جای softmax similarity را می‌گیرد و هدف دوم، calibration احتمال‌هاست.

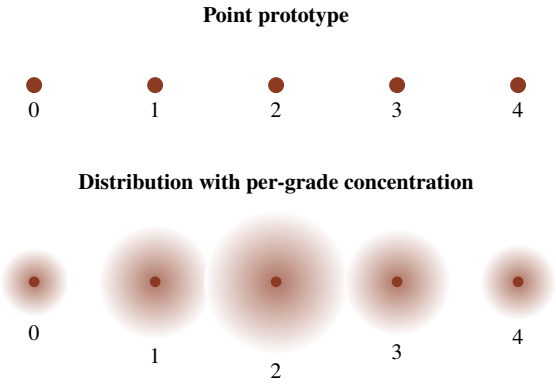
شکل ۳۲ گردش کار کامل جهت ۳ را نشان می‌دهد: هر درجه یک von Mises–Fisher distribution با mean direction و trainable concentration است و mixture posterior آن‌ها جای similarity softmax را می‌گیرد. protocol آزمایش‌ها در شکل ۳۶ آمده است.




**شکل ۳۲:** گردش کار کامل جهت ۳: mean directionها و concentrationهای trainable، vMF mixture posterior با محاسبهٔ پایدار Bessel function، loss function با concentration prior و تأکید بر metricهای calibration.

## ۱.۴ انگیزه و شکاف پژوهشی

مرز درجه‌های DR قطعی نیست و اختلاف نظر درجه‌بندها بیشتر میان درجه‌های ۱ و ۲ و میان ۲ و ۳ دیده می‌شود. یک prototype تک‌نقطه‌ای نمی‌تواند این ابهام را نشان دهد. در جهت ۳ هر درجه یک توزیع روی unit sphere است: یک mean direction که درجه را مکان‌یابی می‌کند و یک concentration که نشان می‌دهد درجه چقدر روشن تعریف شده است. نمایش احتمالاتی پیش‌تر در سمت تصویر بررسی شده است (POE [۱۰])، اما prototypeها احتمالاتی سمت متن با constraint ترتیبی، برای درجه‌بندی few-shot، در مرور منابع این پژوهش یافت نشد. هدف دوم این جهت calibration است: احتمال‌هایی که با دقت واقعی هم‌خوانی دارند، برای کاربرد بالینی ارزشمندند.




**شکل ۳۳:** از نقطه به توزیع: درجه‌های مبهم‌تر (مانند ۱ تا ۳) می‌توانند concentration کمتر و پراکندگی بیشتری بیاموزند.

## ۲.۴ مدل von Mises–Fisher برای هر درجه

von Mises–Fisher distribution (vMF) روی sphere $S^{D-1}$ با mean direction $\mu$ و concentration $\kappa$ چنین است:

$$\mathrm{vMF}(z;\,\mu,\kappa) = C_D(\kappa)\,\exp(\kappa\,\mu^\top z), \qquad C_D(\kappa) = \frac{\kappa^\nu}{(2\pi)^{\nu+1} I_\nu(\kappa)}, \qquad \nu = \frac{D}{2} - 1 = 511 \tag{۱.۴}$$

تابع $I_\nu$ modified Bessel function of the first kind است. برای هر درجه، مانند جهت ۱ یک بردار آزاد روی sphere است که از میانگین ۲۵ توصیف بالینی جهت ۲ (با frozen encoder) آغاز می‌شود، و $\kappa_k = \exp(\ell_k)$ با مقدار اولیهٔ ۱۰۰ آموخته می‌شود. این مقدار اولیه همان CLIP logit scale است.

## ۳.۴ امتیازدهی: vMF mixture posterior

تصویر با mixture posteriorای از پنج توزیع طبقه‌بندی می‌شود. ثابت $\log C_D(\kappa^0)$ برای همهٔ درجه‌ها یکسان است و در softmax حذف می‌شود؛ کم کردن آن در double precision، logitها را در مقیاس CLIP نگه می‌دارد. مقدار $\log C_D$ در $\kappa = 100$ حدود ۲۰۰۰+ است و جمع آن در single precision حدود چهار رقم اعشار را از بین می‌برد:

$$\mathrm{logit}_k = \kappa_k\,\hat{\mu}_k^\top z + \log C_D(\kappa_k) - \log C_D(\kappa^0), \qquad p(k \mid z) = \mathrm{softmax}_k(\mathrm{logit}_k) \tag{۲.۴}$$

دو ویژگی این امتیازدهی مهم است:

۱. اگر همهٔ $\kappa_k$ برابر باشند، posterior دقیقاً CLIP similarity softmax با مقیاس $\kappa$ است؛ پس حالت zero-shot همان zero-shot classifier با میانگین توصیف‌هاست.

۲. اگر درجه‌ای پهن‌تر شود ($\kappa$ کمتر)، برای تصاویری که از همهٔ میانگین‌ها دورند احتمال بیشتری می‌گیرد؛ این همان رفتار هموارسازی است که SMS به similarityها تحمیل می‌کند، اما اینجا جزء خود مدل است و در آزمون هم وجود دارد.

در ablation، امتیازدهی دیگری هم بررسی می‌شود: similarity مورد انتظار با prototypeای که از توزیع درجه برداشته شود. نسبت mean resultant length $A_D(\kappa) = I_{\nu+1}(\kappa)/I_\nu(\kappa)$ است؛ برای نمونه $A_D(100) \approx 0.0967$ که با مقیاس similarityهای واقعی CLIP هم‌خوانی دارد:

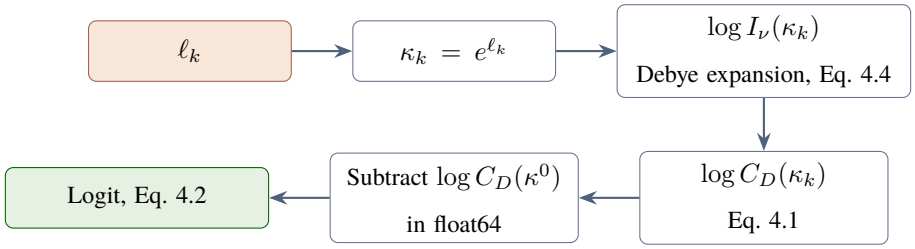
$$\text{logit}_k = 100 \cdot \frac{A_D(\kappa_k)}{A_D(\kappa^0)}\, \hat{\mu}_k^\top z \tag{۳.۴}$$

## ۴.۴ محاسبهٔ پایدار Bessel function

در مرتبهٔ $\nu = 511$ تابع $I_\nu$ در دقت معمولی فرومی‌ریزد؛ برای نمونه، تابع `scipy.special.iv` در $\kappa = 50$ مقدار صفر و در $\kappa = 100$ مقداری از مرتبهٔ $10^{-294}$ برمی‌گرداند. به همین دلیل لگاریتم آن با uniform asymptotic expansion (Debye expansion) و نخستین جملهٔ تصحیحی محاسبه می‌شود [۱۲]:

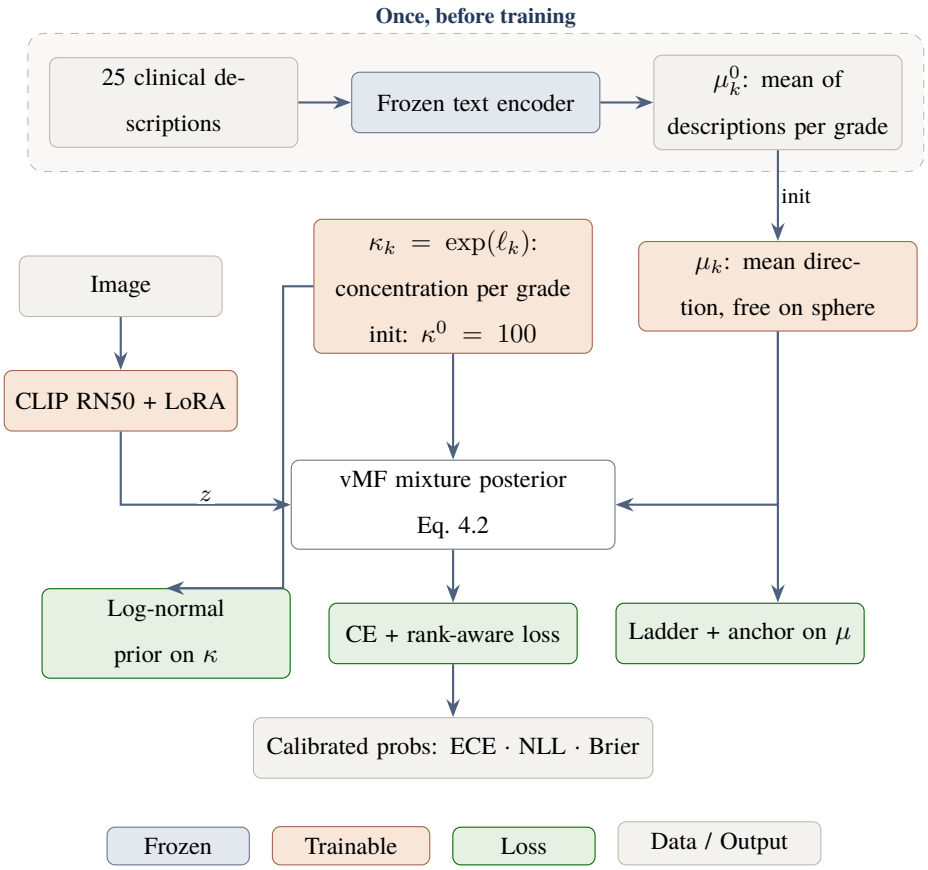
$$\begin{aligned} \log I_\nu(\kappa) &\approx \eta - \tfrac{1}{2}\log(2\pi) - \tfrac{1}{4}\log(\nu^2+\kappa^2) + \log\!\Big(1 + \frac{u_1(t)}{\nu}\Big), \\ \eta &= \sqrt{\nu^2+\kappa^2} + \nu \log \frac{\kappa}{\nu + \sqrt{\nu^2+\kappa^2}}, \qquad t = \frac{\nu}{\sqrt{\nu^2+\kappa^2}}, \qquad u_1(t) = \frac{3t - 5t^3}{24} \end{aligned} \tag{۴.۴}$$

این تقریب در بازهٔ $\kappa \in [1, 1000]$ با محاسبهٔ دقت دلخواه کتابخانهٔ mpmath مقایسه شده و relative error آن حدود $10^{-11}$ است. تقریب نسبت به $\kappa$ هموار و مشتق‌پذیر است و gradient مستقیماً از آن عبور می‌کند.




**شکل ۳۴:** مسیر محاسبهٔ vMF logit. gradient از همهٔ مراحل تا $\ell_k$ عبور می‌کند.

## ۵.۴ معماری




**شکل ۳۵:** معماری جهت ۳. هر درجه دو جزء trainable دارد: mean direction و concentration.

## ۶.۴ loss functionها

CE loss و ranking-aware loss روی logitهای vMF محاسبه می‌شوند. constraintهای ladder (رابطهٔ ۱.۲) و anchor (رابطهٔ ۳.۲) روی mean directionها اعمال می‌شوند. برای concentrationها یک log prior ــ نرمال وجود دارد، چون در few-shot regime $\kappa$ بدون constraint می‌تواند فرو بریزد یا منفجر شود:

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \mathcal{L}_{\text{rank}} + \mathcal{L}_{\text{ladder}}(\hat{\mu}) + \mathcal{L}_{\text{anchor}}(\hat{\mu}) + w_\kappa \sum_k \left(\log \kappa_k - \log \kappa^0\right)^2, \qquad w_\kappa = 0.1 \qquad (۵.۴)$$

SMS در مدل اصلی خاموش است، چون نقش آن را overlap توزیع‌ها بر عهده دارد؛ نسخهٔ «SMS +» در ablation این فرض را می‌آزماید. path constraint و pairwise loss هم خاموش‌اند.

**جدول ۱۵:** اجزای loss function جهت ۳

| جزء | روی چه چیزی | وزن | نقش |
|---|---|---|---|
| cross-entropy | vMF logit | ۱ | طبقه‌بندی درست |
| ranking-aware loss | vMF logit | ۱ | شکل posterior unimodal |
| ladder | $\hat{\mu}_k$ | ۱ | ترتیب فاصلهٔ mean directionها |
| anchor | $\hat{\mu}_k, \hat{\mu}_k^0$ | ۱ | حفظ دانش زبانی |
| concentration prior | $\log \kappa_k$ | ۰/۱ | جلوگیری از فروریختن یا انفجار $\kappa$ |

## ۷.۴ بهینه‌سازی

mean directionها با نرخ $10^{-4}$، بدون weight decay و با normalisation پس از هر گام آموخته می‌شوند. لگاریتم concentrationها گروه جداگانه‌ای با نرخ $10^{-2}$ و بدون weight decay دارند. دلیل نرخ جداگانه این است که $\log \kappa$ حدود ۴/۶ است و با نرخ عمومی $10^{-4}$ در طول ۵۰ epoch تقریباً ثابت می‌ماند. parameterهای trainable ۱,۱۸۸,۲۷۲ + ۵,۱۲۰ + ۵ = ۱,۱۹۳,۳۹۷ است.

**جدول ۱۶:** گروه‌های parameter در optimizer جهت ۳

| گروه | تعداد | learning rate | weight decay | پس از هر گام |
|---|---|---|---|---|
| LoRA تصویر | ۱,۱۸۸,۲۷۲ | $10^{-4}$ | $10^{-4}$ | — |
| mean directionها $\mu$ | ۵,۱۲۰ | $10^{-4}$ | ۰ | normalisation |
| لگاریتم concentration $\ell$ | ۵ | $10^{-2}$ | ۰ | — |

## ۸.۴ داده، ارزیابی و تأکید بر calibration

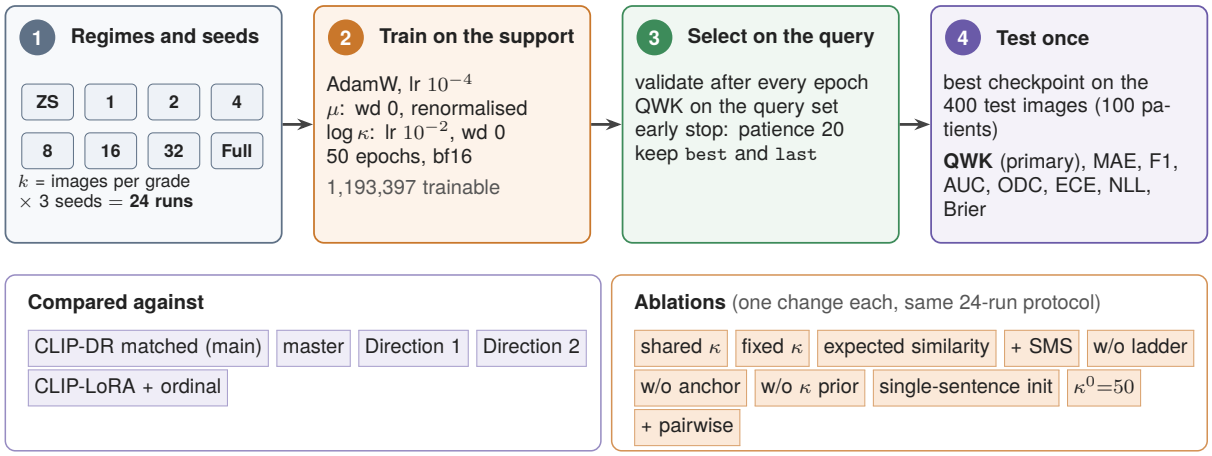
داده، protocol ۲۴ اجرایی و همهٔ metricهای بخش ۷.۱ بدون تغییر به کار می‌روند. چون ادعای اصلی این جهت calibration است، جدول‌ها و منحنی‌های $k$ افزون بر QWK، MAE و ODC، metricهای ECE و NLL را هم برای همهٔ مدل‌ها نشان می‌دهند و Brier score هم گزارش می‌شود. تشخیص‌های هر epoch علاوه بر ماتریس فاصله، ladder و فاصله از anchor، مقدار $\kappa$ هر درجه را هم ثبت می‌کند؛ مسیر تغییر $\kappa$ نشان می‌دهد مدل کدام درجه‌ها را مبهم‌تر یافته است.

## ۹.۴ baselineها و ablationها

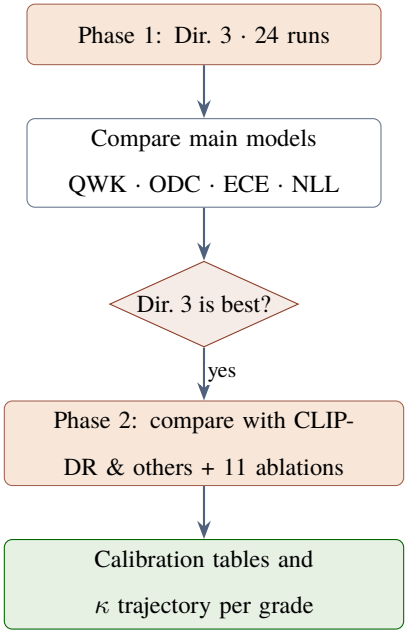
مرجع اصلی مقایسه matched CLIP-DR است، چون SMS همان جزئی است که جهت ۳ جایگزینش می‌کند. مدل master، جهت‌های ۱ و ۲، مدل‌های جدول ۶ و CLIP-LoRA با lossهای ترتیبی هم در مقایسه حضور دارند.

**جدول ۱۷:** ablationها جهت ۳

| آزمایش | تغییر | پرسشی که پاسخ می‌دهد |
|---|---|---|
| $\kappa$ مشترک | یک concentration برای همهٔ درجه‌ها (یک دمای (trainable | آیا ابهام جداگانهٔ هر درجه لازم است؟ |
| $\kappa$ ثابت | concentration آموخته نمی‌شود | مدل قطعی با همان مقداردهی |
| similarity مورد انتظار | رابطهٔ ۳.۴ به‌جای ۲.۴ | کدام امتیازدهی بهتر است؟ |
| SMS + | افزودن SMS | آیا overlap توزیع‌ها جای SMS را می‌گیرد؟ |
| بدون $\kappa$ prior / anchor / ladder | وزن همان جزء صفر | سهم هر constraint |
| مقداردهی با یک جملهٔ بالینی | جملهٔ جهت ۱ به‌جای میانگین ۵ توصیف | اثر میانگین‌گیری توصیف‌ها |
| $\kappa^0 = 50$ | توزیع‌های پهن‌تر در آغاز | حساسیت به مقدار اولیه |
| pairwise loss + | افزودن distance-weighted pairwise loss | سهم این loss در جهت ۳ |




**شکل ۳۶:** protocol آزمایش‌های جهت ۳.




**شکل ۳۷:** گردش کار آزمایش‌های جهت ۳.

# metric موفقیت و جمع‌بندی

**metric موفقیت در هر چهار بخش**

مدلی برتر شمرده می‌شود که در میانگین سه seed، QWK بالاتری در regimeهای few-shot داشته باشد و هم‌زمان در confusion matrixاش خطاها با دور شدن از قطر کاهش یابند (ODC نزدیک به ۱ و error mass نزولی بر حسب فاصله). برای جهت ۳، کاهش ECE و NLL بدون افت QWK شرط لازم ادعای calibration است.

**جدول ۱۸:** مقایسهٔ چهار مدل از نظر اجزا

| جزء | مدل پایه | جهت ۱ | جهت ۲ | جهت ۳ |
|---|---|---|---|---|
| LoRA تصویر ($r = 16$) | دارد | دارد | دارد | دارد |
| نمایش درجه | prompt رتبه‌ای | بردار آزاد | میانگین توصیف‌ها | توزیع vMF |
| text encoder در آموزش | frozen، هر گام | فقط مقداردهی | LoRA، هر گام | فقط مقداردهی |
| رتبه loss + CE | دارد | دارد | دارد | دارد (روی logit vMF) |
| SMS | دارد | دارد | دارد | ندارد |
| anchor / ladder | ندارد | دارد / دارد | دارد / دارد | دارد / دارد |
| smooth path | ندارد | دارد | ندارد | ندارد |
| constraint ویژه | توکن interpolation | مسیر | description ordering | $\kappa$ prior |
| trainable parameter | ۱,۱۹۸,۰۰۰ | ۱,۱۹۳,۳۹۲ | ۱,۲۶۲,۰۰۰ | ۱,۱۹۳,۳۹۷ |

# واژه‌نامه

**جدول ۱۹:** معادل‌های به‌کاررفته در سند

| اصطلاح فارسی | معادل انگلیسی |
|---|---|
| رژیم کم‌نمونه | few-shot regime |
| مجموعهٔ پشتیبان / پرس‌وجو | support / query set |
| نمونهٔ اولیه | prototype |
| توکن بافت / توکن رتبه | context token / rank token |
| تطبیق کم‌رتبه | low-rank adaptation (LoRA) |
| زیان آگاه از رتبه | ranking-aware loss |
| هموارسازی ماتریس شباهت | similarity matrix smoothing (SMS) |
| زیان دوتایی وزن‌دار با فاصله | distance-weighted pairwise loss |
| کاپای وزنی درجه‌دوم | quadratic weighted kappa (QWK) |
| سازگاری افت ترتیبی | ordinal decay consistency (ODC) |
| خطای کالیبراسیون مورد انتظار | expected calibration error (ECE) |
| لگاریتم درست‌نمایی منفی | negative log-likelihood (NLL) |
| توزیع فون‌میزس–فیشر / تمرکز | von Mises–Fisher distribution / concentration |
| بسط مجانبی یکنواخت | uniform asymptotic (Debye) expansion |
| آزمایش حذفی | ablation study |

# References


[1] A. Radford et al. Learning transferable visual models from natural language supervision. In *ICML*, 2021.

[2] W. Li et al. OrdinalCLIP: Learning rank prompts for language-guided ordinal regression. In *NeurIPS*, 2022.

[3] Q. Yu et al. CLIP-DR: Textual knowledge-guided diabetic retinopathy grading with ranking-aware prompting. In *MICCAI*, 2024.

[4] R. Wang et al. Learning-to-rank meets language: Boosting language-driven ordering alignment for ordinal classification. In *NeurIPS*, 2023.

[5] J. Silva-Rodríguez, S. Hajimiri, I. Ben Ayed, J. Dolz. A closer look at the few-shot adaptation of large vision-language models. In *CVPR*, 2024.

[6] M. Zanella, I. Ben Ayed. Low-rank few-shot adaptation of vision-language models. In *CVPR Workshops*, 2024.

[7] E. J. Hu et al. LoRA: Low-rank adaptation of large language models. In *ICLR*, 2022.

[8] Y. Yang et al. Delving into deep imbalanced regression. In *ICML*, 2021.

[9] S. Pratt et al. What does a platypus look like? Generating customized prompts for zero-shot image classification. In *ICCV*, 2023.

[10] W. Li et al. Learning probabilistic ordinal embeddings for uncertainty-aware regression. In *CVPR*, 2021.

[11] C. P. Wilkinson et al. Proposed international clinical diabetic retinopathy and diabetic macular edema disease severity scales. *Ophthalmology*, 110(9), 2003.

[12] NIST Digital Library of Mathematical Functions, §10.41: Asymptotic expansions for large order.

[13] R. Liu et al. DeepDRiD: Diabetic retinopathy—grading and image quality estimation challenge. *Patterns*, 3(6), 2022.